HOCHSCHULE KOBLENZ
University of Applied Sciences

Hierarchical Risk Parity und klassische Portfolio-Optimierung im Vergleich

Bachelorarbeit

im Studiengang Wirtschaftsmathematik
Hochschule Koblenz, RheinAhrCampus,
Remagen

vorgelegt von
Niclas Treib
geb. am 21.09.1999 in Bad Neuenahr-Ahrweiler

Erstprüfer:	Prof. Dr. Anselm Hudde
Zweitprüfer:	Prof. Dr. Martina Brück
Durchgeführt bei:	Hochschule Koblenz

22. September 2026

Inhaltsverzeichnis

1 Einleitung **1**

2 Theoretische Grundlagen **2**
2.1 Erwartungswert der Rendite . . . 2
2.2 Varianz und Standardabweichung . . . 2
2.3 Sharpe-Ratio . . . 2
2.4 Kovarianz . . . 3
2.5 Korrelation . . . 3
2.6 Kovarianz- und Korrelationsmatrix . . . 3
2.7 Kondition einer Matrix . . . 4

3 Das Markowitz-Modell **5**
3.1 Der rationale Investor . . . 5
3.2 Erwartete Rendite und Varianz eines Portfolios . . . 6
3.3 Diversifikation . . . 6
3.4 Opportunitätsbereich . . . 9
3.5 Effizienter Rand . . . 9
3.6 Das Optimierungsverfahren . . . 10
3.7 Beispiel . . . 14
3.8 Kritik am Markowitz-Modell . . . 14

4 Das Hierarchical-Risk-Parity-Modell **16**
4.1 Hierarchisches Clustering . . . 16
4.2 Quasi-Diagonalisierung . . . 18
4.3 Recursive Bisection . . . 18
4.4 Fazit zu HRP . . . 20

5 Empirischer Vergleich **21**
5.1 Zusammenstellung des Portfolios . . . 21
5.2 Methodik und Parameter . . . 22
5.3 Ergebnisse und Vergleich . . . 24

6 Ausblick **32**

7 Anhang **35**
7.1 Performance-Plots . . . 35
7.2 Konditions-Plots . . . 37
7.3 Area-Plots . . . 38
7.4 Tabellen . . . 41
7.5 Python-Code . . . 41

Abbildungsverzeichnis

1 μ-σ-Diagramm (Kremer, 2023, S. 11) 5
2 Diversifikation im μ-σ-Diagramm (Kremer, 2023, S. 23) 8
3 Opportunitätsbereich (Kremer, 2023, S. 29) 9
4 Effizienzlinie (Kremer, 2023, S. 30) 10
5 Dendrogramm für 5 Aktien 17
6 Konditionszahl (halbjährlich) über die Zeit 24
7 Performance der Modelle bei halbjährlicher Rebalancing-Frequenz 25
8 Volatilitäten der Allokationsansätze (halbjährlich) 26
9 Area-Plot der Gewichte für die Markowitz-Optimierung (halbjährlich) . . 27
10 Area-Plot der Gewichte für das HRP-Modell (halbjährlich) 27
11 Area-Plot der Gewichte für das marktgewichtete Portfolio (halbjährlich) . 28
12 Performance der Modelle bei jährlicher Rebalancing-Frequenz 35
13 Performance der Modelle bei quartalsweiser Rebalancing-Frequenz 35
14 Performance der Modelle bei jährlicher Rebalancing-Frequenz (2006-2015) 36
15 Performance der Modelle bei quartalsweiser Rebalancing-Frequenz (2006-2015) 36
16 Konditionszahl (jährlich) über die Zeit 37
17 Konditionszahl (quartalsweise) über die Zeit 37
18 Area-Plot der Gewichte für die Markowitz-Optimierung (jährlich) 38
19 Area-Plot der Gewichte für das HRP-Modell (jährlich) 38
20 Area-Plot der Gewichte für das Market-Cap-Portfolio (jährlich) 39
21 Area-Plot der Gewichte für die Markowitz-Optimierung (quartalsweise) . 39
22 Area-Plot der Gewichte für das HRP-Modell (quartalsweise) 40
23 Area-Plot der Gewichte für das Market-Cap-Portfolio (quartalsweise) . . . 40

Tabellenverzeichnis

1 Optimale Gewichtsallokation des Markowitz-MVP 14
2 Zusammensetzung des Portfolios nach Regionen und Unternehmen 22
3 Vergleich der Performance über verschiedene Rebalancing-Frequenzen (naiv) 29
4 Vergleich der Performance über verschiedene Rebalancing-Frequenzen . . 30
5 Modellvergleich der mathematischen Optimierungsansätze (inkl. MSR) . . 31
6 Durchschnittliche Konditionszahl der Kovarianzmatrizen (unregularisiert) nach Rebalancing-Frequenz 41

Symbolverzeichnis

R_t	Rendite eines Assets zum Zeitpunkt t
S_t	Kurswert eines Assets zum Zeitpunkt t
$\hat{\mu}_i$	Geschätzte erwartete Rendite des i-ten Assets
$\hat{\sigma_i}^2$	Geschätzte Varianz des i-ten Assetes
Cov	Kovarianz zweier Assets
$\rho_{i,j}$	Korrelation zweier Assets
Σ	Korrelationsmatrix der Asset-Renditen
κ	Konditionszahl
λ	Eigenwert
μ_p	Erwartete Rendite eines Portfolios p
${\sigma_p}^2$	Erwartete Varianz eines Portfolios p
w_i	Portfoliogewicht des i-ten Assets
$\mathbf{1}$	Ein Vektor bestehend nur aus Einsen
h_i	i-te nach null umgestellte Gleichheitsnebenbedingung
g_j	j-te nach null umgestellte Ungleichheitsnebenbedingung
$d_{i,j}$	Distanzmetrik zwischen den Assets i und j
C_i	i-tes Cluster im Dendrogramm von HRP
r_t	Logarithmische Rendite
$\Sigma_{i,\epsilon}$	Kovarianzmartix nach Anwendung von Shrinkage
I	Einheitsmatrix
ϵ	Der bei Shrinkage addierte Wert
SR	Sharpe Ratio
r_f	Risikoloser Zinssatz

1 Einleitung

Seit über sieben Jahrzehnten ist die klassische Portfoliotheorie nach Harry Markowitz der Standard in der Portfolioallokation. Das Modell liefert zwar theoretisch solide Ergebnisse, zeigt in der Praxis jedoch deutliche Schwächen: Es reagiert empfindlich auf Schätzfehler in den Eingabedaten und neigt dazu, das Kapital stark auf wenige, schwach volatile Titel zu konzentrieren.

Problemstellung und Forschungsfrage

Durch Schätzfehler in den historischen Renditen und Kovarianzen führt die Markowitz-Optimierung in der Praxis häufig zu instabilen Gewichten und einer unzureichenden Diversifikation. Neuere Verfahren aus dem Bereich des Machine Learnings versuchen, genau diese Schwächen zu beheben. Marcos López de Prado hat dafür den *Hierarchical Risk Parity* (HRP)-Ansatz entwickelt. Das Verfahren nutzt hierarchische Baumstrukturen, um ohne die fehleranfällige Invertierung der Kovarianzmatrix auszukommen.

Aus dieser Problemstellung ergibt sich die zentrale Forschungsfrage dieser Arbeit:

> *Führt der Hierarchical Risk Parity-Ansatz in einem empirischen Backtest über 20 Jahre zu einer stabileren Portfolioallokation und einer überlegenen Risiko-Rendite-Struktur im Vergleich zur klassischen Markowitz-Optimierung sowie gängigen Benchmarks?*

Zielsetzung der Arbeit

Ziel dieser Arbeit ist es, die Performance und die Allokationsstabilität von Markowitz- und HRP-Portfolios unter realistischen Marktbedingungen zu analysieren. Dabei soll untersucht werden, ob der Verzicht auf Matrixinversionen des HRP-Ansatzes in der Praxis einen messbaren Mehrwert für Investoren liefert.

Methodische Vorgehensweise

Zur Beantwortung der Forschungsfrage wird ein historischer Rebalancing-Backtest über einen Zeitraum von 20 Jahren durchgeführt. Auf Basis eines definierten Portfolios werden die Gewichte der Modelle in regelmäßigen Intervallen neu berechnet. Neben der klassischen Markowitz-Optimierung und dem HRP-Verfahren werden das naiv diversifizierte $(1/N)$ sowie das marktgewichtete Portfolio als Benchmarks herangezogen, um den tatsächlichen Optimierungseffekt zu ermitteln.

Inhaltliche Abgrenzung

Die empirische Untersuchung beschränkt sich auf ein Universum von 30 ausgewählten Assets. Der Fokus der Arbeit liegt bewusst auf dem Vergleich der mathematischen Allokationsmechanismen. Transaktionskosten werden im Rahmen dieses Backtests nicht berücksichtigt, um die reine Modellperformance isoliert zu bewerten.

2 Theoretische Grundlagen

Um das Optimierungsverfahren nach Markowitz und das HRP-Modell zu untersuchen ist es zunächst notwendig, die theoretischen Grundlagen zu klären.

2.1 Erwartungswert der Rendite

Der Erwartungswert der Rendite wird klassischer Weise durch das arithmetische Mittel der Beobachtungen geschätzt. Für die Schätzung ergibt sich damit:

$$\hat{\mu}_i = \frac{1}{T} \sum_{t=1}^{T} R_{i,t}. \tag{1}$$

Wobei T die Anzahl der Beobachtungen ist.

2.2 Varianz und Standardabweichung

Die Varianz misst die quadratische Abweichung vom Erwartungswert. Die Varianz wird in dieser Arbeit als $\hat{\sigma}^2$ oder mit Var bezeichnet. Sie ist gegeben als

$$\hat{\sigma}_i^2 = \frac{1}{T-1} \sum_{t=1}^{T} (R_{i,t} - \hat{\mu}_i)^2. \tag{2}$$

Durch $T - 1$ im Nenner ist der Schätzer $\hat{\sigma}_i^2$ für die Varianz erwartungstreu (Bessel-Korrektur).

Die Standardabweichung bzw. Volatilität ergibt sich als $\hat{\sigma}_i$.

2.3 Sharpe-Ratio

Das Sharpe-Ratio misst das Verhältnis von Rendite zur Volatilität. Ein hohes Sharpe-Ratio deutet also auf eine effizientere Risikoallokation hin, während ein niedriges Sharpe-Ratio das Gegenteil andeutet. Es dient als zentrales Maß für die Diversifikation eines Portfolios.

$$SR = \frac{\mu_p - r_f}{\sigma_p} \tag{3}$$

2.4 Kovarianz

Zur Analyse des gemeinsamen Bewegungsverhaltens zweier Assets i und j benötigen wir die Kovarianz. Sie beschreibt die gemeinsame Bewegung durch:

$$\mathrm{Cov}(R_i, R_j) = \frac{1}{T-1} \sum_{t=1}^{T} (R_{i,t} - \hat{\mu}_i)(R_{j,t} - \hat{\mu}_j). \tag{4}$$

Bemerkung: Die Kovarianz eines Assets mit sich selbst entspricht der Varianz, denn

$$\mathrm{Cov}(R_i, R_i) = \frac{1}{T-1} \sum_{t=1}^{T} (R_{i,t} - \hat{\mu}_i)(R_{i,t} - \hat{\mu}_i) = \frac{1}{T-1} \sum_{t=1}^{T} (R_{i,t} - \hat{\mu}_i)^2 = \hat{\sigma}_i^2. \tag{5}$$

2.5 Korrelation

Die Kovarianz hängt von der Skalierung der Renditen ab und ist somit nicht leicht zu interpretieren. Weshalb man als leichter zu interpretierendes Maß die Korrelation betrachtet. Sie ist auf das Intervall $[-1, 1]$ normiert und berechnet sich wie folgt:

$$\rho_{i,j} = \frac{\mathrm{Cov}(R_i, R_j)}{\hat{\sigma}_i \cdot \hat{\sigma}_j}, \quad \text{mit } \rho_{i,j} \in [-1, 1] \quad \forall\ i, j. \tag{6}$$

Wobei $\rho_{ij} = 0$ bedeutet, dass zwei Assets unkorreliert sind. Und $\rho_{ij} = \pm 1$ den perfekt korrelierten bzw. perfekt unkorrelierten Fall beschreibt.

Bemerkung: Die Korrelation eines Assets mit sich selbst ist immer 1, denn:

$$\rho_{i,i} = \frac{\mathrm{Cov}(R_i, R_i)}{\hat{\sigma}_i \cdot \hat{\sigma}_i} = \frac{\mathrm{Var}(R_i)}{\hat{\sigma_i}^2} = \frac{\hat{\sigma_i}^2}{\hat{\sigma_i}^2} = 1. \tag{7}$$

Das würden man auch intuitiv vermuten, denn eine Aktie korreliert immer perfekt mit sich selbst.

2.6 Kovarianz- und Korrelationsmatrix

Um die Kovarianz bzw. die Korrelation mehrerer Assets simultan darzustellen nutzt man Matrizen. Sie werden als Kovarianz bzw. Korrelationsmatrix bezeichnet. Sie haben die Form:

$$\Sigma = \begin{pmatrix} \mathrm{Var}(R_1) & \mathrm{Cov}(R_1, R_2) & \cdots & \mathrm{Cov}(R_1, R_n) \\ \mathrm{Cov}(R_2, R_1) & \mathrm{Var}(R_2) & \cdots & \mathrm{Cov}(R_2, R_n) \\ \vdots & \vdots & & \vdots \\ \mathrm{Cov}(R_n, R_1) & \mathrm{Cov}(R_n, R_2) & \cdots & \mathrm{Var}(R_n) \end{pmatrix}, \tag{8}$$

$$R = \begin{pmatrix} 1 & \rho_{1,2} & \cdots & \rho_{1,n} \\ \rho_{2,1} & 1 & \cdots & \rho_{2,n} \\ \vdots & \vdots & & \vdots \\ \rho_{n,1} & \rho_{n,2} & \cdots & 1 \end{pmatrix}. \tag{9}$$

Sowohl die Kovarianzmatrix Σ als auch die Korrelationsmatrix R sind per Definition quadratisch und auch symmetrisch. Diese Eigenschaften werden später noch nützlich sein.

2.7 Kondition einer Matrix

Ein zentrales Problem bei der Portfolio-Optimierung ist die numerische Stabilität. Diese wird maßgeblich durch die Konditionszahl κ beeinflusst. Für eine invertierbare Matrix ist die Konditionszahl bezüglich der Spektralnorm definiert als das Verhältnis vom größten zum kleinsten Eigenwert:

$$\kappa(\Sigma) = \frac{\lambda_{\max}(\Sigma)}{\lambda_{\min}(\Sigma)}. \tag{10}$$

Aus dieser Definition folgt direkt dass κ immer größer oder gleich 1 sein muss. Denn für den Fall dass unsere Matrix nur einen Eigenwert hat erhalten wir für κ den Wert 1. In allen anderen Fällen teilen wir den größten durch den kleinsten Eigenwert, was immer zu einem $\kappa > 1$ führt.

Die Konditionszahl lässt sich wie folgt interpretieren:

Je kleiner die Konditionszahl, desto stabiler ist die Matrix. D.h. die Matrix reagiert weniger empfindlich gegenüber Änderungen in den Eingangsparametern.

3 Das Markowitz-Modell

In den 50er Jahren des letzten Jahrhunderts entwickelte Harry Markowitz ein Modell für die klassische Portfoliotheorie. Das Ziel dieses Modells ist es, ein optimales Verhältnis zwischen dem Risiko und der Rendite herzustellen. Dieses Ziel soll durch Diversifikation erreicht werden.

3.1 Der rationale Investor

Markowitz geht für sein Modell von einem „rationalem Investor“ aus. Der rationale Investor verhält sich stets risikoavers und wird gleichzeitig jede Gelegenheit nutzen um Gewinne zu erzielen. Dieses Verhalten lässt sich durch ein μ-σ-Diagramm veranschaulichen:

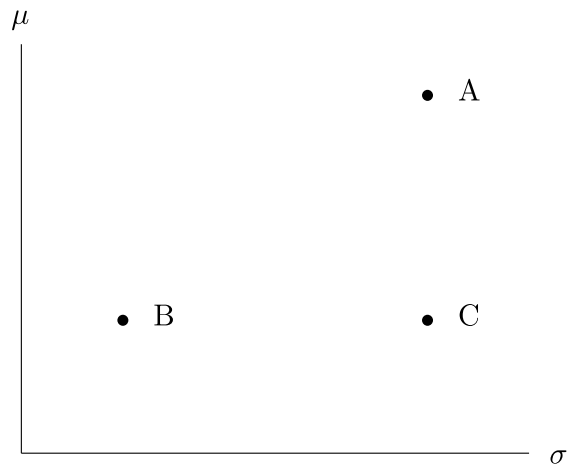


Abbildung 1: μ-σ-Diagramm (Kremer, 2023, S. 11)

Hat ein Investor die Wahl zwischen Investment B und Investment C, so entscheidet er sich für B. Denn Investment B hat die gleiche erwartete Rendite wie C, gleichzeitig aber ein geringeres Risiko.

Muss er jedoch eine Auswahl zwischen Investment A und Investment C treffen, so entscheidet er sich für A. Investment A liefert nämlich bei gleichem Risiko eine höhere erwartete Rendite.

3.2 Erwartete Rendite und Varianz eines Portfolios

Hat man ein Portfolio bestehend aus n Wertpapieren mit jeweils einem Gewicht w. Wobei die Summe der Gewichte 1 ergibt. So berechnet sich die erwartete Rendite des Portfolios als

$$\mu_p = \sum_{i=1}^{n} w_i \mu_i = \langle w, \mu \rangle. \tag{11}$$

Die Varianz eines Portfolios entspricht dem Risiko. Sie ergibt sich als

$$\sigma_p^2 = \sum_{i=1}^{n} \sum_{j=1}^{n} w_i w_j \sigma_{ij} = w^T \Sigma w. \tag{12}$$

3.3 Diversifikation

Unter Diversifikation versteht man das Verteilen des Risikos auf mehrere Assets. Sie ist das fundamentale Prinzip hinter dem Modell von Markowitz. Die einfachste Form der Diversifikation ist die sogenannte **naive Diversifikation**. Hier werden einfach alle Assets gleich gewichtet. Um uns die Diversifikationseffekte klar zu machen betrachen wir zwei Aktien S^1 und S^2 mit den Gewichten w und $(1 - w)$.

Für die Portfoliorendite und die Portfoliovarianz gelten nach Kremer (2023, S. 22) die folgenden Zusammenhänge:

$$\mu_p = \mu_2 + w(\mu_1 - \mu_2), \tag{13}$$

und

$$\sigma_p^2 = (w\sigma_1)^2 + ((1 - w)\sigma_2)^2 + 2w(1 - w)\sigma_1\sigma_2\rho. \tag{14}$$

Nun sollen zwei Extremfälle betrachtet werden um die Auswirkungen von Diversifikation auf ein Portfolio verständlich zu machen.

$\rho = 1$:

Für $\rho = 1$ lässt sich die Portfoliovarianz schreiben als:

$$\sigma_p^2 = (w\sigma_1)^2 + ((1 - w)\sigma_2)^2 + 2w(1 - w)\sigma_1\sigma_2.$$

Mit Hilfe der binomischen Formeln lässt sich das zu folgendem Ausdruck umformen:

$$\sigma_p^2 = (w\sigma_1 + (1-w)\sigma_2)^2,$$

bzw.

$$\sigma_p = \sigma_2 + w(\sigma_1 - \sigma_2).$$

Wir sehen also, dass, wenn wir w gleich 1 setzen, dass nur das Risiko von Wertpapier 1, also σ_1 übrig bleibt. Umgekehrt gilt das Gleiche für Wertpapier 2 bzw. σ_2. Für die erwartete Rendite gilt das Gleiche. D.h. für den Bereich zwischen S^1 und S^2 ergibt sich folgende Geradengleichung:

$$\begin{pmatrix}\sigma_p \\ \mu_p\end{pmatrix} = \begin{pmatrix}\sigma_2 \\ \mu_2\end{pmatrix} + w\begin{pmatrix}\sigma_1 - \sigma_2 \\ \mu_1 - \mu_2\end{pmatrix}.$$

Wir sehen also, dass unsere Aktien S^1 und S^2 durch eine Gerade im μ-σ-Diagramm verbunden sind. Wenn wir w gleich 1 oder 0 setzen, landen wir genau auf S^1 bzw. S^2.

$\rho = -1$**:**

Setzen wir ρ auf -1, dann erhalten wir:

$$\sigma_p^2 = (w\sigma_1)^2 + ((1-w)\sigma_2)^2 - 2w(1-w)\sigma_1\sigma_2.$$

Auch hier kommen wir unter Verwendung der binomischen Formeln auf:

$$\sigma_p^2 = (w\sigma_1 - (1-w)\sigma_2)^2$$

Da eine Standardabweichung nicht negativ sein kann, erhalten wir für σ_p

$$\sigma_p = |w\sigma_1 - (1-w)\sigma_2|.$$

Da in diesem Fall die Aktien negativ korreliert sind, kann man sich überlegen ob es ein Portfolio gibt, welches gar kein Risiko mehr aufweist. Hierzu setzen wir σ_p gleich 0 und formen dann nach w um. Dann erhalten wir

$$w = \frac{\sigma_2}{\sigma_1 + \sigma_2}.$$

Für unser μ-σ-Diagramm erhalten wir also folgende Fallunterscheidung:

$$\sigma_p = \begin{cases} \sigma_2 - w(\sigma_1 + \sigma_2) & \text{für } 0 \leq w \leq \frac{\sigma_2}{\sigma_1+\sigma_2} \\ w(\sigma_1 + \sigma_2) - \sigma_2 & \text{für } \frac{\sigma_2}{\sigma_1+\sigma_2} < w \leq 1 \end{cases}.$$

Wir sehen also, dass wir zwei Geraden ausgehend vom Nullpunkt auf der μ-Achse erhalten. Für $-1 < \rho < 1$ liegen die Verbindungslinien also immer zwischen den beiden betrachteten Extremfällen $\rho = 1$ und $\rho = -1$. Im μ-σ-Diagramm sieht das also folgendermaßen aus:

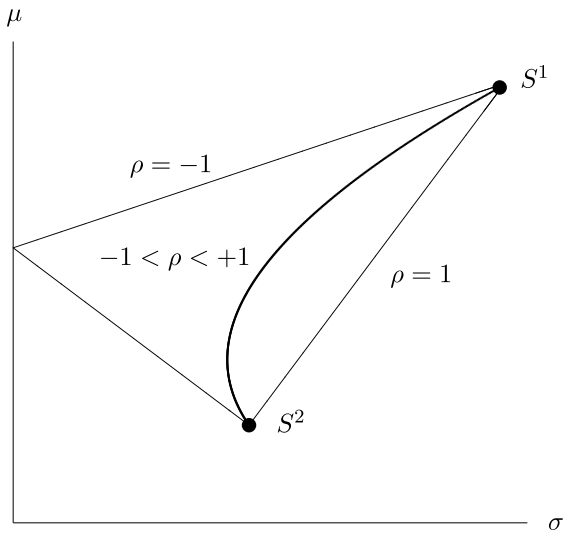


Abbildung 2: Diversifikation im μ-σ-Diagramm (Kremer, 2023, S. 23)

Wir sehen wo die verschiedenen Portfolios im μ-σ-Diagramm liegen. In der Praxis treten der perfekt korrelierte und der perfekt unkorrelierte Fall allerdings nicht auf. Weshalb wir immer eine bogenförmige Verbindung zwischen zwei Aktien erhalten. Eine weitere Erkenntnis ist, dass es bei den bogenförmigen Kurven immer auch ein Portfolio gibt, wo das Risiko am geringsten ist. Nämlich den Punkt der im Diagramm am weitesten links liegt. Diesen Punkt erreicht man durch das Anpassen der Gewichte, also durch Diversifikation des Portfolios.

3.4 Opportunitätsbereich

Da in der Realität immer $-1 < \rho < 1$ gilt. Lässt sich die Menge aller möglichen Portfolios im μ-σ-Diagramm wie folgt darstellen.

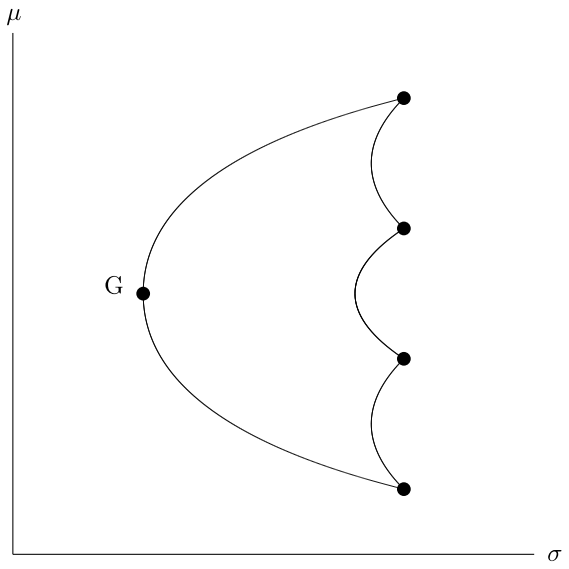


Abbildung 3: Opportunitätsbereich (Kremer, 2023, S. 29)

Diese Menge von Portfolios bezeichnen wir als Opportunitätsbereich. Seine Form ähnelt einem „Regenschirm“ (Kremer, 2023, S. 28). Der Punkt G bezeichnet das Portfolio mit dem global geringsten Risiko.

3.5 Effizienter Rand

Durch die Annahme des rationalen Investors können wir den Opportunitätsbereich verkleinern. Der rationale Investor investiert nur in die Portfolios die bei gleicher Rendite ein geringeres Risko aufweisen. Gleichzeitig fallen alle Portfolios weg, die bei gleichem Risiko eine geringere Rendite aufweisen. Die übrigen Portfolios liegen auf dem **Effizienten Rand** oder der **Effizienzlinie**.

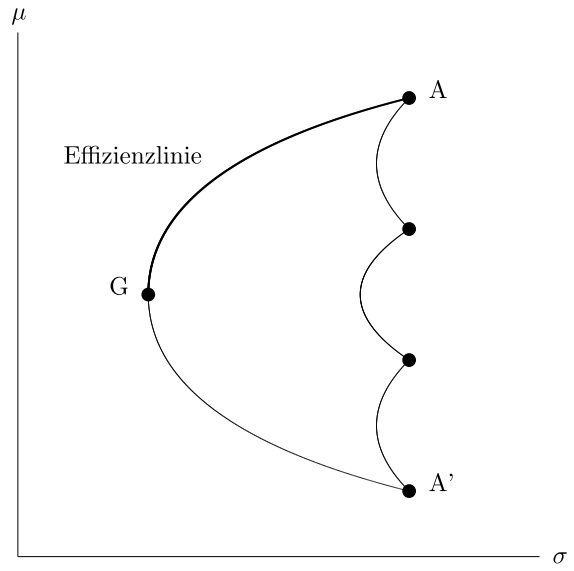


Abbildung 4: Effizienzlinie (Kremer, 2023, S. 30)

Der effiziente Rand beschreibt also alle theoretisch optimalen Portfolios. In der Praxis stellt sich für einen Anleger die Frage nach dem spezifisch für ihn optimalen Portfolio. Diese Frage führt zu der Portfolio-Optimierung nach Markowitz.

3.6 Das Optimierungsverfahren

Nachdem der effiziente Rand die Menge aller theoretisch optimalen Portfolios definiert hat, besteht die praktische Aufgabe darin, das spezifisch für einen Investor optimale Portfolio auf dem effizienten Rand zu identifizieren. Dieser Prozess der Portfolio-Allokation wird als quadratisches Optimierungsproblem unter Nebenbedingungen formuliert.

In dieser Arbeit liegt der Fokus auf der Risikominimierung, weshalb als Zielfunktion die vorher definierte Portfoliovarianz (12) dient

$$\min_{w} \sigma_p^2 = w^T \Sigma w. \tag{15}$$

Das Optimierungsproblem wäre trivialer Weise mit $w_i = 0$ gelöst. Da das Risiko am geringsten ist wenn wir in gar keine Aktie investieren, denn dann gilt $\sigma_p^2 = 0$. Weshalb man Nebenbedingungen formulieren muss.

Die erste Nebenbedingungen ist die **Budgetrestriktion**. Hiermit stellt man sicher dass das gesamte Kapital investiert wird. Außerdem will man nicht über das Gesamtkapital hinaus gehen, also keine Kredite aufnehmen. Die erste Nebenbedingung lautet also

$$\sum_{i=1}^{n} w_i = 1. \tag{16}$$

Neben der Budgetrestriktion wird in dieser Arbeit auch eine Nebenbedingung die Leerverkäufe ausschließt benötigt. Hierfür nutzt man eine **Nicht-Negativitäts-Bedingung**. Es soll also stets gelten

$$w_i \geq 0 \quad \text{für alle } i = 1, ..., n \tag{17}$$

Da die Kovarianzmatrix Σ positiv definit ist, handelt es sich um ein strikt konvexes Optimierungsproblem mit linearen Nebenbedingungen. Für solche Probleme existiert eine eindeutige Lösung. Das aus der Lösung resultierende Portfolio nennen wir **Minimum-Varianz-Portfolio** (MVP).

Um die mathematische Struktur zu verdeutlichen, betrachten wir zunächst das Optimierungsproblem nur unter der Budgetrestriktion. Dieses Problem lässt sich analytisch mit der Lagrange-Funktion lösen.

Die Lagrange-Funktion hat die Struktur

$$L(w, \lambda) = \text{Zielfunktion} - \lambda \cdot (\text{Nebenbedingung} = 0). \tag{18}$$

Die Zielfunktion wurde in (15) bereits definiert. Die Budgetrestriktion nach null umgestellt lautet $\sum_{i=1}^{n} w_i - 1$. Also erhält man für die Lagrange-Funktion den Ausdruck

$$L(w, \lambda) = w^T \Sigma w - \lambda(\mathbf{1}^T w - 1).$$

Die Nebenbedingung wurde hier von der Summenschreibweise in die Vektorschreibweise übertragen. Um das Minimum zu bestimmen, müssen die partiellen Ableitungen nach w und nach λ gebildet und gleich Null gesetzt werden:

$$\frac{\partial L}{\partial w} = 2\Sigma w - \lambda \mathbf{1} \stackrel{!}{=} 0 \tag{19}$$

und

$$\frac{\partial L}{\partial \lambda} = \mathbf{1}^T w - 1 \stackrel{!}{=} 0. \tag{20}$$

Aus Gleichung (19) lässt sich nun der Zusammenhang zwischen den optimalen Gewichten und der Kovarianzmatrix isolieren. Durch Umstellen ergibt sich:

$$w = \frac{1}{2} \lambda \Sigma^{-1} \mathbf{1}. \tag{21}$$

Um den Lagrange-Multiplikator λ zu eliminieren setzen wir (21) in die Budgetrestriktion (16) ein. Dadurch erhalten wir den Ausdruck

$$\mathbf{1}^T \left(\frac{1}{2} \lambda \Sigma^{-1} \mathbf{1} \right) = 1.$$

$\frac{1}{2}\lambda$ ist eine Skalar, weshalb man es in der Gleichung nach vorne ziehen kann. Stellen wir die gesamten Gleichung jetzt nach genau diesem Skalar um, so erhalten wir

$$\frac{1}{2}\lambda = \frac{1}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}$$

Setzt man diesen Term nun in die Gleichung (21) ein, erhält man für die Gewichte des Minimum-Varianz-Portfolios die Gleichung

$$w_{MVP} = \frac{\Sigma^{-1}\mathbf{1}}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}. \tag{22}$$

Man sieht also, dass die Gewichte des Minimum-Varianz-Portfolios direkt von der Inversen der Kovarianzmatrix abhängen. Auf diese Eigenschaft wird in einem späteren Kapitel noch einmal Bezug genommen werden.

KKT-Bedingungen für das Portfolioproblem:

Das Optimierungsverfahren wie es bisher betrachtet wurde, berücksichtigt nur die Budgetrestriktion. Allerdings möchten wir in dieser Arbeit Leerverkäufe ausschließen. Nimmt man also diese Nebenbedingung hinzu, kann man nicht mehr so einfach eine analytische Lösungen für das Minimum-Varianz-Portfolio bestimmen. Denn es existiert dann zusätzlich noch eine Ungleichheitsnebenbedingung (17). Um dieses Optimierungsproblem zu lösen wird die Langrange-Gleichung um die der Kuhn-Tucker-Bedinungen erweitert.

Allgemein erhält man für die Langrange-Gleichung mit Kuhn-Tucker den Ausdruck (Nickel et al., 2022, S. 260)

$$L(w, \lambda, \delta) = f(w) + \sum_{i=1}^{l} \lambda_i \cdot h_i(w) + \sum_{j=1}^{m} \delta_j \cdot g_j(w). \tag{23}$$

h beschreibt in dieser Gleichung die nach null umgestellten Gleichheitsnebenbedingungen und g beschreibt die nach null umgestellten Ungleichheitsnebenbediungen.

Um nun den Vektor der optimalen Portfoliogewichte zu bestimmen, müssen die folgenden Kuhn-Tucker-Bedingungen erfüllt sein (Nickel et al., 2022, S. 260)

$$\nabla L = \nabla f(w^*) + \sum_{i=1}^{l} \lambda_i \nabla h_i(w^*) + \sum_{j=1}^{m} \delta_j \nabla g_j(w^*) = 0. \tag{24}$$

w^* bezeichnet den Vektor mit den optimalen Portfoliogewichten. Die weiteren Kuhn-Tucker-Bedingungen lauten

1. $h_i(w^*) = 0$
2. $g_j(w^*) \leq 0$
3. $\delta_j \geq 0$
4. $\delta_j \cdot g_j(w^*) = 0 \quad \forall j = 1, ..., m$.

Die erweiterte Langrange-Gleichung für das in dieser Arbeit betrachtete Minimum-Varianz-Portfolio lautet also

$$L = w^T \Sigma w + \lambda(\mathbf{1}^T w - 1) + \sum_{j=1}^{n} \delta_j(-w_j). \tag{25}$$

Numerische Lösung des Optimierungsproblems:

Ein solches Optimierungsproblem kann man numerisch mithilfe des Critical-Line-Algorithmus (CLA) lösen. Die Idee des CLA besteht darin, den effizienten Rand nicht durch unzählige Einzelberechnungen zu schätzen, sondern ihn systematisch durch die Identifikation von sogenannten Eckportfolios (Corner Portfolios) exakt zu konstruieren. Diese Eckportfolios sind genau die Punkte, an denen entweder eine Aktie die Nullschranke erreicht und aus dem Portfolio ausscheidet oder eine Aktie neu in das Portfolio aufgenommen wird. Durch dieses sukzessive Abwandern des effizienten Randes liefert der CLA eine exakte Lösung für das Minimum-Varianz-Portfolio und berücksichtigt dabei alle Ungleichheitsrestriktionen.

Bemerkung: Als alternativer Ansatz kann das Maximum-Sharpe-Ratio-Portfolio (MSR) betrachtet werden. Im Gegensatz zum zuvor hergeleiteten Minimum-Varianz-Portfolio strebt dieser Ansatz keine Risikominimierung an, sondern maximiert gezielt das Risiko-Rendite-Verhältnis des Portfolios.

Unter der Annahme eines risikofreien Zinssatzes von $r_f = 0$ lautet das mathematische Optimierungsproblem zur Maximierung des Sharpe-Ratio:

$$\max_w SR(w) = \frac{w^T \mu}{\sqrt{w^T \Sigma w}} \tag{26}$$

unter den bekannten Restriktionen der Budgetbedingung (16) und des Leerverkaufsverbots (17). Da diese Zielfunktion aufgrund des Quotienten mit der Quadratwurzel im

Nenner nicht linear und nicht konvex ist, lässt sie sich nicht direkt analytisch über den Lagrange-Ansatz lösen, wie es beim MVP der Fall war.

Da der primäre Fokus dieser Arbeit auf dem empirischen Vergleich der Performance- und Stabilitätseigenschaften der Modelle liegt, wird auf eine detaillierte analytische Herleitung der notwendigen Transformationsschritte verzichtet. Das Optimierungsproblem wird im praktischen Teil dieser Arbeit numerisch gelöst. Hierzu wird ein Software-Framework verwendet, welches das nicht lineare Problem über eine quadratische Umformulierung mittels des Python-Pakets `cvxopt` exakt, deterministisch und numerisch stabil abbildet.

3.7 Beispiel

Um die Funktionsweise des Minimum-Varianz-Portfolios unter Ausschluss von Leerverkäufen zu verdeutlichen, wird das Optimierungsverfahren auf fünf DAX-Aktien angewendet: BMW, Mercedes-Benz, Allianz, BASF und Bayer. Die Schätzung der Kovarianzmatrix Σ basiert auf den historischen Tagesrenditen des entsprechenden Untersuchungszeitraums.

Es ergeben sich für dieses spezifische Anlageuniversum folgende optimale Gewichte des MVP:

Tabelle 1: Optimale Gewichtsallokation des Markowitz-MVP

Asset	BMW	Mercedes-Benz	Allianz	BASF	Bayer
Gewicht	0,0583	0,0348	0,7295	0,1684	0,0091

Anhand dieser Verteilung wird das Optimierungsverhalten direkt in der Praxis sichtbar. Obwohl das Universum aus fünf DAX-Titeln besteht, sind die Gewichte stark konzentriert. Die Allianzversicherung erhält fast 73 % des investierten Kapitals, während BMW nur 5 % und Bayer sogar weniger als 1 % erhält.

3.8 Kritik am Markowitz-Modell

Obwohl der Critical-Line-Algorithmus das Minimum-Varianz-Portfolio exakt berechnet, gibt es berechtigte Kritik am Modell von Markowitz. Die Probleme liegen dabei nicht in der Rechenmethode selbst, sondern in der Beschaffenheit der Eingangsdaten.

Es wurde bereits in Gleichung (22) gezeigt, dass die Portfoliogewichte direkt mit der Inversen der Kovarianzmatrix zusammenhängen. Da diese Matrix allerdings, wie wir später noch sehen werden, numerisch sehr instabil ist, führt eine kleine Fehlschätzung der Varianzen bzw. Kovarianzen zu großen Veränderungen im Gewichtsvektor. Da alle

Einträge der Kovarianzmatrix aus historischen Daten geschätzt werden, kann dies zu Problemen führen.

Ein weiteres Problem ist, dass Markowitz dazu neigt die Gewichte zu „konzentrieren“. Das bedeutet, dass wenige Aktien stark gewichtet werden, während viele andere Aktien mit einem Gewicht von null versehen werden. Das Modell neigt dazu hoch volatile Aktien mit null zu gewichten, was natürlich im ersten Moment logisch erscheint, denn man will ja eigentlich ein Portfolio mit möglichst geringer Volatilität (MVP). Doch dieses Verhalten steht im Konflikt mit dem Diversifikationsgedanken. Denn das Ziel eines Anlegers ist es das Risiko auf mehrere Aktien zu verteilen.

Der letzte Kritikpunkt am Markowitz-Modell, der hier betrachtet wird, ist, dass dieses Modell die Kovarianzen der Vergangenheit betrachtet. Oft sind die Kovarianzen zwischen zwei Aktien aber keine konstanten Werte, sondern sie verändern sich mit der Zeit. D.h. die Annahme dass die Kovarianzen zwischen den Aktien immer den Kovarianzen des vorherigen Zeitraums entsprechen ist in der Praxis häufig falsch. Hierbei handelt es sich aber um eine notwendige Modellannahme, denn man kann die Kovarianzen der Zukunft nicht vorhersagen.

Zusammenfassend lässt sich festhalten, dass die klassische Portfolio-Optimierung nach Markowitz trotz ihrer mathematischen Eleganz signifikante Schwächen in der Praxis aufweist. Weshalb wir uns im nächsten Kapitel mit einem alternativen Modell beschäftigen, dem **Hierachical-Risk-Parity-Modell**.

4 Das Hierarchical-Risk-Parity-Modell

Um die im letzten Kapitel angesprochenen Schwächen der klassischen Portfolio-Optimierung zu umgehen, hat Marcos López de Prado im Jahr 2016 das Hierarchical-Risk-Parity-Modell entwickelt. Dieses Modell verzichtet komplett auf die Matrixinversionen. Stattdessen nutzt HRP Methoden des maschinellen Lernens, um die hierarchische Korrelationsstruktur der Assets abzubilden und für die Gewichtung zu nutzen.

Der HRP-Agorithmus lässt sich in drei Phasen unterteilen:

1. Das **hierarchische Clustering**, um die Ähnlichkeitsstruktur der Assets zu bestimmen
2. Die **Quasi-Diagonalisierung**, um die Kovarianzmatrix basierend auf dieser Struktur neu zu ordnen
3. Die **Recursive Bisection**, um das Kapital rekursiv über die Hierarchieebenen zu verteilen.

4.1 Hierarchisches Clustering

Der erste Schritt des Modells besteht darin die Assets in einer hierarchischen Baumstruktur anzuordnen. Die Idee hierbei ist, dass die Assets keine homogene Masse sind, sondern es eine natürliche Gruppierung von Assets gibt die sich ähnlich verhalten (bspw. alle Aktien der Automobilbranche).

Um diese Struktur mathematisch zu erfassen wird zunächst die Korrelationsmatrix R der Renditen betrachtet (9). Aus dieser Korrelationsmatrix leitet man die Distanzmatrix ab. Hierfür nutzt man die Metrik (López de Prado, 2018, S. 224)

$$d_{i,j} = \sqrt{\frac{1}{2}(1 - \rho_{i,j})}. \tag{27}$$

Diese Distanzmetrik sorgt dafür dass perfekt positiv korrrelierte Assets ($\rho = 1$) eine Distanz von null aufweisen und perfekt negativ korrelierte Assets ($\rho = -1$) eine Distanz von 1. Auf Basis dieser Distanzen wird eine agglomeratives Clusteringverfahren angewendet, dabei werden die Assets sukzessive zu Paaren und zu Clustern zusammengefasst.

Um die Distanz zwischen neu entstehenden Clustern im Verlauf des Algorithmus mathematisch zu definieren, wird in Abweichung zu López de Prado (2018, S. 228), welcher das *Single-Linkage-Verfahren* verwendet, in dieser Arbeit das **Ward-Verfahren** (**Ward1963**) implementiert. Diese Modifikation begründet sich darin, dass das Single-Linkage-Verfahren in der Praxis zu stark asymmetrischen Kettenstrukturen (*Chaining-Effekt*) neigt. Das Ward-Verfahren hingegen minimiert bei jedem Fusionsschritt das Wachstum der totalen Varianz innerhalb der Cluster. Mathematisch wird die Distanz

zwischen zwei Clustern A und B über den Zuwachs der Fehlerquadratsumme (ΔESS) definiert, der entstehen würde, wenn diese zu einem gemeinsamen Cluster $A \cup B$ vereint werden:

$$\Delta ESS_{A,B} = \frac{|A| \cdot |B|}{|A| + |B|} \cdot \|\mathbf{x}_A - \mathbf{x}_B\|^2, \tag{28}$$

wobei $|A|$ und $|B|$ die Anzahl der Elemente in den jeweiligen Clustern repräsentieren und $\mathbf{x}_A$ bzw. $\mathbf{x}_B$ die dazugehörigen Cluster-Schwerpunkte darstellen. Durch diese gezielte Minimierung der Varianzzunahme führt das Ward-Verfahren tendenziell zu sehr kompakten, homogenen und hierarchisch ausgewogenen Clustern.

Das Ergebnis dieses gesamten Prozesses ist ein Dendrogramm, welches die Nähe der verschiedenen Assets zueinander veranschaulicht.

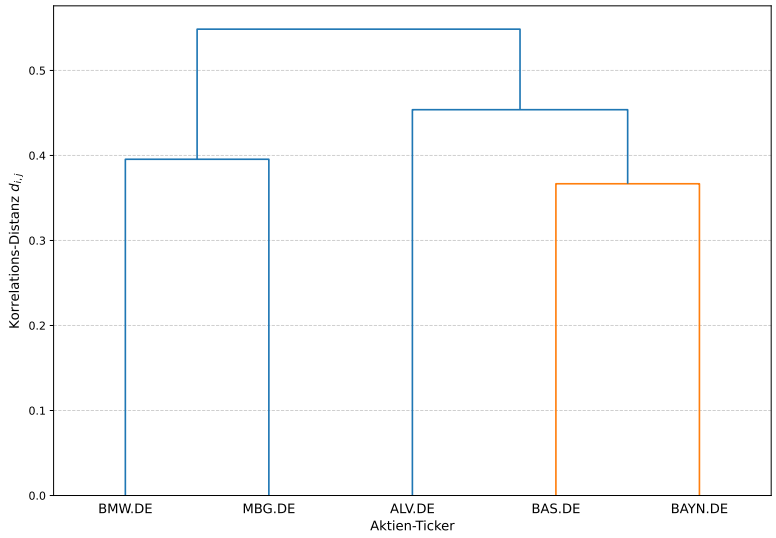


Abbildung 5: Dendrogramm für 5 Aktien

Wir sehen hier ein beispielhaftes Dendrogramm, bestehend aus den Aktien von BMW, Mercedes-Benz, der Allianzversicherung, BASF und Bayer. Man erkennt die 2 Hauptcluster, Cluster 1 besteht aus den beiden Aktien von BMW und Mercedes-Benz und Cluster 2 beinhaltet die Aktien von BASF und Bayer. Die Allianz bildet ein eigenes Cluster. Man kann also direkt sehen, dass die Aktien nach Branchen geclustert wurden. Auf der Y-Achse sind die Distanzen verzeichnet. Die Automobilaktien liegen ca. bei einer Distanz von 0,4 während die Aktien der Pharmaindustrie etwas darunter liegen (ca. 0,37). Die Allianz erhält ihr eigenes Cluster, da ihr Abstand zu den anderen Aktien höher ist, sie unterscheidet sich also zu stark vom Rest. Die Distanz zu den Aktien von BASF und Bayer liegt ca. bei 0,45.

Nach dem durch das Clustering die hierarchische Struktur der Assets identifiziert wurde, liefert die Anordnung der Endknoten die Sortierung für den zweiten Schritt des HRP-Algorithmus. In Abbildung 5 ergibt sich z.B. von links nach rechts die Reihenfolge: BMW, Mercedes, Allianz, BASF, Bayer.

4.2 Quasi-Diagonalisierung

Die aus dem hierarchischen Clustering gewonnene Sequenz der Endknoten bildet das Fundament für die Quasi-Diagonalisierung. Bei diesem Schritt geht es darum, die Zeilen und Spalten der ursprünglichen Kovarianz- bzw. Korrelationsmatrix so anzuordnen, dass stark korrelierende Aktien (bzw. Assets mit geringer Distanz (27)) in der Matrix nebeneinander platziert werden.

Formal lässt sich diese strukturelle Transformation als eine lineare Abbildung über eine Permutationsmatrix $P \in \{0,1\}^{N \times N}$ beschreiben. Diese Matrix ordnet die Indizes der Assets auf Basis der im Clustering-Schritt ermittelten Reihenfolge neu an:

$$R_g = PRP^T, \tag{29}$$

wobei R die ursprüngliche Korrelationsmatrix und R_g die neu geordnete, quasi-diagonalisierte Matrix darstellt. Eine Permutationsmatrix besitzt in jeder Zeile und jeder Spalte exakt einen Eintrag von eins und ansonsten nur Nulleinträge. Daraus ergibt sich die Eigenschaft, dass ihre Inverse identisch mit ihrer Transponierten ist ($P^{-1} = P^T$).

Durch diese Sortierung konzentrieren sich die hohen Korrelationen unmittelbar um die Hauptdiagonale der Matrix R_g, während die Werte abseits der Diagonalen gegen null tendieren. Im Gegensatz zur klassischen Portfolio-Optimierung nach Markowitz ist für den gesamten Prozess zu keinem Zeitpunkt eine Matrixinversion notwendig, da lediglich Zeilen und Spalten vertauscht werden. Dies macht das Verfahren numerisch stabiler als Markowitz.

4.3 Recursive Bisection

Der finale Schritt des HRP-Algorithmus ist die **Recursive Bisection**. Dabei wird das Portfoliokapital auf Basis der quasi-diagonalen Struktur schrittweise von oben nach unten (*Top Down*) verteilt. Im Gegensatz zu Markowitz, wo die Gewichte simultan bestimmt werden, arbeitet der HRP-Algorithmus rekursiv entlang der Baum-Hierarchie.

Bestimmung der Gewichte:

Das Portfolio wird zunächst auf der obersten Ebene des Baumes (mit einem initialen Budget $W = 1.0$) in zwei disjunkte Teilcluster C_1 und C_2 unterteilt. Für die zwei Teilcluster wird die Varianz bestimmt. Dabei wird innerhalb der Cluster eine **Inverse-Variance-Gewichtung** (IVP) unterstellt. Die daraus resultierende Cluster-Varianz V_i

für ein Teilcluster C_i (mit $i \in \{1, 2\}$) berechnet sich formal durch (López de Prado, 2016, S. 8):

$$V_i = g_i^T \Sigma_i g_i. \tag{30}$$

Wobei Σ_i die reduzierte Sub-Kovarianzmatrix der im spezifischen Cluster C_i enthaltenen Assets darstellt und g_i die Gewichtung innerhalb des Clusters bezeichnet. Die einzelnen Komponenten berechnen sich als (López de Prado, 2016, S. 8):

$$g_k = \frac{\frac{1}{\sigma_k^2}}{\sum_{j \in C_i} \frac{1}{\sigma_j^2}}. \tag{31}$$

Die Annahme einer vereinfachten Inverse-Variance-Gewichtung (IVP) erfüllt an dieser Stelle im HRP-Modell eine rein strategische Funktion und fungiert nicht als finales Allokationswerkzeug. Sie dient als robustes Hilfskonstrukt, um das Risiko eines gesamten Asset-Clusters auf eine einzige, repräsentative Varianzkennzahl herunterzubrechen. Da die IVP-Methodik ausschließlich die Einzelvarianzen der Hauptdiagonale verwendet, bleibt die Bestimmung der Cluster-Varianz V_i völlig unbeeinflusst von den potenziell instabilen Korrelationsschätzungen abseits der Diagonale. Dies stellt eine bewusste methodische Stabilisierung dar: Sie garantiert, dass die Top-Down-Kapitalaufteilung zwischen den übergeordneten Clustern numerisch absolut stabil bleibt, selbst wenn die Titelauswahl innerhalb eines Clusters eine extreme Multikollinearität aufweist.

Die Gewichte zwischen den Clustern berechnet man über den Allokationsfaktor α als (López de Prado, 2018, S. 230):

$$\alpha = 1 - \frac{V_1}{V_1 + V_2}. \tag{32}$$

Das Cluster C_1 erhält daraufhin das aktualisierte Teilbudget $\alpha \cdot W$, während das Cluster C_2 den verbleibenden Anteil $(1-\alpha) \cdot W$ zugewiesen bekommt. Diesen Prozess wiederholt man rekursiv so lange, bis jedes Asset auf Ebene der Endknoten ein finales, absolutes Gewicht zugeordnet bekommen hat.

Dieses rekursive Verfahren kann man sich nun anhand des in Abbildung 5 vorgestellten Beispiels mit den fünf DAX-Aktien verdeutlichen. Basierend auf der im Dendrogramm sichtbaren Hierarchie und der durch die Quasi-Diagonalisierung ermittelten Reihenfolge [BMW, Mercedes, Allianz, BASF, Bayer] vollzieht der Algorithmus die Allokation in folgenden Schritten:

1. **Erste Bisektion (Top-Level):** Das Gesamtportfolio wird zunächst in zwei Hauptgruppen unterteilt. In diesem Fall bildet der Automobil-Sektor (BMW und Mercedes) das erste Cluster C_1, während die restlichen drei Assets (Allianz, BASF

und Bayer) das Cluster C_2. Gemäß der Varianz dieser beiden Blöcke wird das Gesamtkapital erstmals aufgeteilt.

2. **Zweite Bisektion:** Innerhalb des zweiten Clusters findet eine weitere Aufteilung statt. Hierbei wird die Allianz als einzelnes Asset von dem verbleibenden Paar aus BASF und Bayer getrennt. Das Gewicht von C_2 wird also zwischen der Allianzversicherung und dem Chemie-Cluster aufgeteilt.

3. **Finale Ebene:** In der untersten Hierarchiestufe wird das Kapital innerhalb der eng verwandten Paare verteilt. Das für den Automobil-Sektor reservierte Kapital wird zwischen BMW und Mercedes aufgeteilt; analog wird das Kapital des Chemie-Clusters zwischen BASF und Bayer partitioniert.

Diese Vorgehensweise verdeutlicht den entscheidenden Vorteil der *Recursive Bisection*: Das Risiko wird zunächst zwischen ökonomisch unterschiedlichen Sektoren (Automobil vs. Finanzen/Chemie) gestreut. Erst innerhalb dieser stabilen Blöcke findet die Feinverteilung auf die Einzelwerte statt. Dies verhindert, dass hohe Korrelationen zwischen ähnlichen Aktien – wie etwa BMW und Mercedes – zu einer instabilen Übergewichtung eines einzelnen Titels führen, wie es bei der klassischen Rendite-Varianz-Optimierung oft der Fall ist.

4.4 Fazit zu HRP

Zusammenfassend lässt sich festhalten, dass das Hierarchical-Risk-Parity-Modell von Marcos López de Prado eine Brücke zwischen der klassischen Portfoliotheorie und dem maschinellen Lernen schlägt. Durch den Verzicht auf die Inversion von Matrizen und die Fokussierung auf die hierarchische Struktur wird eine höhere Robustheit gegenüber Schätzfehlern in den Inputparametern angestrebt. Ob sich diese theoretischen Vorteile in der Praxis bewähren, wird im folgenden Kapitel anhand eines Portfolios aus 30 Aktien empirisch untersucht. Dabei dient die Konditionszahl der Kovarianzmatrix als zentrales Maß, um die numerische Instabilität des klassischen Markowitz-Ansatzes zu verdeutlichen und dem HRP-Modell gegenüberzustellen.

5 Empirischer Vergleich

Nachdem die theoretischen Grundlagen sowohl für das Markowitz-Modell als auch für das Hierarchical-Risk-Paritiy Modell geklärt wurden, folgt im vorliegenden Kapitel der empirische Vergleich der beiden Modelle. Hierfür werden beide Modelle auf ein Portfolio bestehend aus 30 Assets angewendet. Als Benchmarks dienen in diesem Vergleich sowohl die naive Diversifikation (ein Portfolio, in dem alle Assets mit $\frac{1}{N}$ gewichtet werden) als auch ein marktgewichtetes Portfolio (bei dem sich die Gewichtung der einzelnen Aktien proportional nach ihrer Marktkapitalisierung richtet). Der Zeitraum, den wir betrachten wollen, erstreckt sich über 20 Jahre (2006 – 2026).

5.1 Zusammenstellung des Portfolios

Die Auswahl der 30 Assets für dem empirischen Vergleich folgt einer gezielten Strategie, um die Robustheit der Optimierungsalgorithmen unter verschiedenen Marktbedingungen und Korrelationsstrukturen zu testen. Das Portfolio wurde nach folgenden Kriterien zusammengestellt:

1. **Geografische Diversifikation:** Um das Klumpenrisiko einzelner Volkswirtschaften zu reduzieren, deckt das Portfolio mehrere Wirtschaftsregionen ab.

   - **Deutschland:** Die zehn DAX-Aktien decken eine Volkswirtschaft in der Eurozone ab. Vor allem die Industrie und den Finanzsektor.

   - **USA:** Die zehn US-Titel decken primär den Technologie- und Konsumgütersektor ab, welcher historisch andere Wachstums- und Volatilitätsprofile aufweist als europäische Werte.

   - **Japan:** Die neun japanischen Titel bringen eine zusätzliche Diversifikation durch die geringere Korrelation des japanischen Marktes zu westlichen Märkten ein.

2. **Abdeckung von Risikofaktoren:** Die Aufnahme des MSCI Emerging Markets dient als Proxy für die Märkte in Entwicklungsländern. Da sich diese Märkte oft anders verhalten als die Ökonomien von Industrieländern, erhöht dieser Titel nochmal die Heterogenität des Portfolios.

3. **Datenverfügbarkeit:** Es wurden ausschließlich Titel gewählt, die im betrachteten Zeitraum (2006 - 2026) eine kontinuierliche Datenbasis liefern. Das stellt sicher, dass die betrachteten Kovarianzmatrizen nicht durch fehlende Daten verzerrt werden.

4. **Sektorale Streuung:** Innerhalb der verschiedenen Regionen wurde darauf geachtet, dass die Assets aus verschiedenen Sektoren (Industrie, Finanzen, Pharma, Technologie, Konsum) stammen. Da HRP die Aktien nach den Sektoren clustert, ist es wichtig verschiedenen Sektoren abzubilden, um den potenziellen Vorteil dieser Strategie überhaupt sichtbar zu machen.

Folgende Assets wurden nach den oben genannten Kriterien ausgewählt:

Tabelle 2: Zusammensetzung des Portfolios nach Regionen und Unternehmen

Region	**Unternehmen / Assets**
Deutschland	SAP, Siemens, Allianz, Münchener Rück, Deutsche Telekom, DHL Group, Rheinmetall, E.ON, Infineon, Beiersdorf
USA	NVIDIA, Microsoft, Alphabet, Amazon, UnitedHealth, Visa, Procter & Gamble, Costco, NextEra Energy, Lockheed Martin
Japan	Toyota, Sony, Tokyo Electron, Keyence, Mitsubishi UFJ, Nintendo, Shin-Etsu Chemical, Takeda Pharmaceutical, Fast Retailing, Itochu
Global	MSCI Emerging Markets ETF (EEM)

Quelle: Eigene Darstellung, Kursdaten von Yahoo Finance.

Bemerkung:

Die Datenauswahl unterliegt dem sogenannten *Survivorship Bias*. Da für den 20-jährigen Untersuchungszeitraum eine lückenlose Datenbasis vorausgesetzt wird, fließen ausschließlich Unternehmen in die Analyse ein, die über den gesamten Zeitraum am Markt bestehen blieben. Gescheiterte oder insolvente Titel werden somit ausgeschlossen, was zu einer systematischen Überzeichnung der historischen Gesamtperformance führt. Die Ergebnisse sind daher primär als relativer Vergleich der Modellmechanismen unter identischen Datenbedingungen zu verstehen.

5.2 Methodik und Parameter

Um eine belastbare Vergleichbarkeit der Portfoliomodelle im empirischen Kontext zu gewährleisten, ist die Definition einheitlicher Rahmenbedingungen und Modellparameter erforderlich. Der Vergleich erfolgt als rollierender Backtest über den Zeitraum von 2006 bis 2026. Die Wahl des Zeitraums wurde deshalb so getroffen, da sowohl die Finanzkrise 2008 als auch die Covid-19 Pandemie innerhalb dieses Zeitraums liegen.

Für die Durchführung der Simulation wurden folgende Kernparameter festgelegt:

- **Schätzzeitraum (Lookback):** Zur Berechnung der Eingabeparameter wird ein rollierendes Fenster von 12 Monaten verwendet. Dieser Zeitraum stellt sicher dass man genügend Datengrundlage für das Rebalancing hat, jedoch auch auf aktuelle Trends im Markt reagieren kann. Als Datengrundlage dienen die Schlusskurse der einzelnen Handelstage.
- **Rebalancing-Frequenz:** Die Portfolios werden jährlich, halbjährlich sowie quartalsweise neu gewichtet. Die Rebalancing Frequenzen orientieren sich an realistischen Zeiträumen aus der Finanzwelt. Es werden drei verschiedenen Frequenzen betrachtet, um zu prüfen ob sich die Modelle abhängig vom Rebalancing unterschiedlich verhalten, oder ob die Frequenz keine merklichen Auswirkungen auf die jeweilige Performance hat.

- **Benchmarks**: Als Referenzen dienen sowohl die naive Diversifikation $(1/N)$ als auch ein marktgewichtetes Portfolio. Diese Benchmarkportfolios dienen als Vergleichswerte, um zu überprüfen, wie groß der tatsächliche Optimierungseffekt und Mehrwert der betrachteten Portfoliostrategien gegenüber klassischen beziehungsweise passiven Marktanlagen ist. Sollten für einzelne Assets zu bestimmten Rebalancing-Stichtagen keine Daten zur Marktkapitalisierung vorliegen, wird deren Marktkapitalisierung methodisch mit 0 angesetzt, sodass diese Titel für den jeweiligen Zeitraum kein Gewicht im marktgewichteten Portfolio erhalten.

Um die zeitliche Additivität der Renditen zu gewährleisten und die numerische Stabilität der Schätzungen zu verbessern, werden Log-Renditen verwendet. Sie berechnen sich als

$$r_t = \ln\left(\frac{S_t}{S_{t-1}}\right). \tag{33}$$

Wie bereits in Kapitel 3.7 dargelegt, stellt die numerische Instabilität bei der Inversion der Kovarianzmatrix eine zentrale Schwachstelle des Markowitz-Modells dar. Im Rahmen dieser empirischen Untersuchung wird daher die Konditionszahl (10) der Kovarianzmatrizen explizit überwacht. Dies erlaubt es, die theoretisch postulierten Vorteile des HRP-Algorithmus – insbesondere den Verzicht auf die Matrixinversion – anhand der vorliegenden Marktdaten zu validieren.

Für die praktische Umsetzung des klassischen Markowitz-Modells wurde im Optimierungsschritt das sogenannte Shrinkage-Verfahren eingesetzt. Hierbei werden kleine Werte auf der Diagonalen der Kovarianzmatrix addiert, da die Matrix sonst zu nah an der Singularität wäre. Das würde dazu führen dass das Optimierungsverfahren bei gewissen Rebalancing-Schritten nicht konvergiert. Durch diese Regularisierung wird die numerische Stabilität des Algorithmus verbessert, um eine robuste Schätzung der Portfoliogewichte sicherzustellen. Die regularisierten Kovarianzmatrizen berechnen sich also als

$$\Sigma_{i,\epsilon} = \Sigma_i + \epsilon \cdot I. \tag{34}$$

Wobei I die Einheitsmatrix bezeichnet und $\epsilon > 0$ ein kleiner Regularisierungsparameter ist. Im Rahmen dieser Arbeit wird $\epsilon = 10^{-6}$ gewählt.

Als weiteres Bewertungskriterium für die Performance der verschiedenen Modelle wird das bereits in Kapitel 2 definierte Sharpe-Ratio (3) herangezogen. Aus Gründen der Vereinfachung sowie zur Vermeidung von Verzerrungen durch zeitvariante Leitzinsen wird der risikolose Zins in dieser Untersuchung einheitlich mit $r_f = 0$ angesetzt. Die Sharpe-Ratio misst somit direkt das Risiko-Rendite-Verhältnis des jeweiligen Portfolios.

Zusätzlich zu den risikobasierten Ansätzen (MVP und HRP) wird im Rahmen der empirischen Untersuchung das Maximum-Sharpe-Ratio-Portfolio (MSR) als aktiver, renditeorientierter Markowitz-Ansatz implementiert. Dies ermöglicht es zu prüfen, wie sich

ein exakt auf die Maximierung dieser Kennzahl ausgerichteter Algorithmus im Out-of-Sample-Kontext gegenüber Strategien verhält, die primär auf Risikominimierung abzielen.

5.3 Ergebnisse und Vergleich

Zunächst wird die numerische Stabilität betrachtet, denn das ist einer der Hauptkritikpunkte von Marcos López de Prado am Markowitz-Modell (López de Prado, 2018, S. 222).

Da die Kovarianzmatrizen alle symmetrisch sind (siehe (8)), wurde die Konditionszahl in dieser Analyse mit (10) bestimmt. Plottet man nun die Konditionszahl gegen die Zeit erhält man folgenden Graphen.

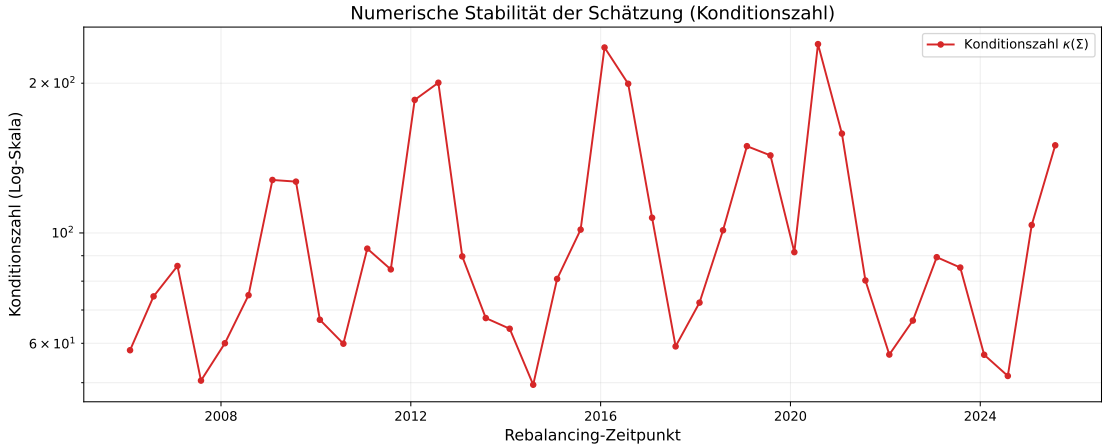


Abbildung 6: Konditionszahl (halbjährlich) über die Zeit

Exemplarisch wird hier die rohe Konditionszahl bei halbjährlicher Rebalancing Frequenz betrachtet, d.h. es wird die Konditionszahl berechnet, bevor das Shrinkage-Verfahren angewendet wird. Dabei zeigt sich, dass die Konditionszahl im Zeitverlauf erheblichen Schwankungen unterliegt. In Phasen erhöhter Konditionszahlen reagiert die Inversion der Kovarianzmatrix sensitiver auf kleine Schätzfehler in den historischen Daten. Diese temporären Phasen schlechter Konditionierung verdeutlichen die Notwendigkeit des Regularisierungsverfahrens (Shrinkage).

Wenn man die Konditionszahl für verschiedene Rebalancing Frequenzen betrachtet, stellt man fest dass die durchschnittliche Konditionszahl fast konstant ist (siehe Tabelle 6 im Anhang). Die maximale Konditionszahl nimmt mit niedriger Rebalancing-Frequenz ab, jedoch auch nur geringfügig. Die Rebalancing-Frequenz scheint also nur einen sehr geringen Einfluss auf die Konditionierung der Kovarianzmatrizen zu haben.

Diese Untersuchung bestätigt also die Behauptung von Marcos López de Prado, dass die Matrizen für die Markowitz-Optimierung schlecht konditioniert sein können (vgl. López de Prado (2018, S. 222)), und dadurch kleine Fehler in den geschätzten Parametern zu großen Veränderungen in den berechneten Portfoliogewichten führen können. Es wird auch klar, warum die es sinnvoll sein kann einen Algorithmus zu verwenden, der auf Matrixinversionen verzichtet, und somit von numerischen Instabilitäten weniger betroffen ist.

Performance:

Um die Performance der Modelle zu bewerten, werden Kennzahlen wie die Wertentwicklung, Volatilität, das Sharpe-Ratio und die Verteilung der Gewichte betrachtet.

Als erstes betrachtet man die allgemeine Performance. Hierzu schaut man sich die Wertentwicklung der verschiedenen Anlagestrategien über die Zeit an. Exemplarisch wird hier die Wertentwicklung über die Zeit bei halbjährlicher Rebalancing-Frequenz betrachtet.

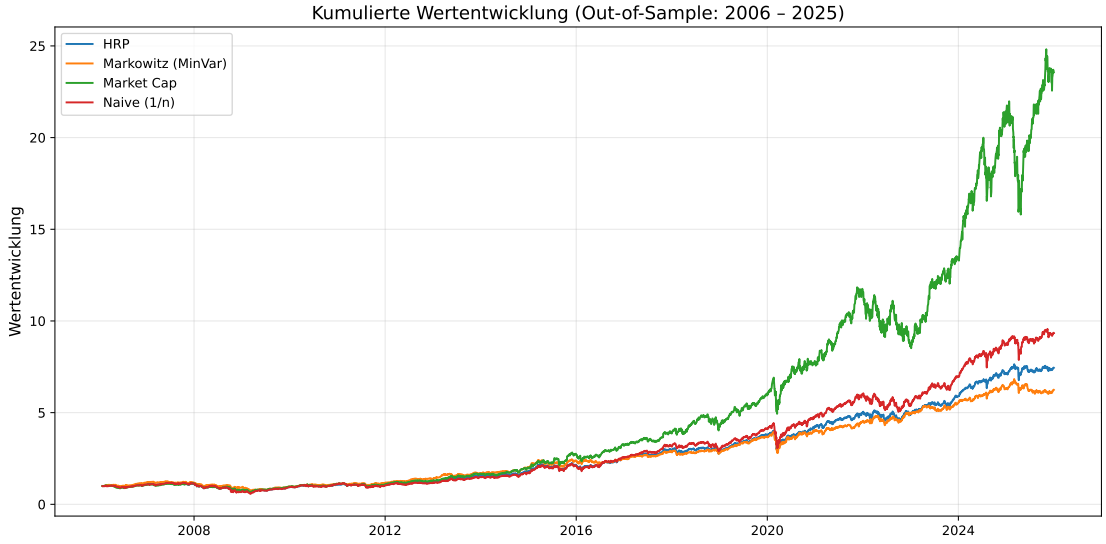


Abbildung 7: Performance der Modelle bei halbjährlicher Rebalancing-Frequenz

Im Performance-Plot der verschiedenen Modelle hat das marktgewichtete Portfolio eindeutig die beste Wertentwicklung. Es gibt einen deutlichen Abstand zu den anderen Allkokationsansätzen, welche wiederum verhältnismäßig nah beieinander liegen. Bemerkenswert ist, dass die naive Diversifikation eine bessere Wertentwicklung aufweist als HRP und Markowitz, zumindest ab 2016.

Gut erkennbar ist, dass die verschiedenen Kurven weitesgehend parallel verlaufen, mit dem Unterschied, dass die Ausschläge unterschiedlich stark ausgeprägt sind. Es lässt sich direkt ableiten, dass das marktgewichtete Portfolio die höchste Volatilität aufweisen muss, denn dort sind die Ausschläge am größten. Auch die naive Diversifikation scheint

eine höhere Volatilität als HRP und Markowitz aufzuweisen. Der Performance-Plot legt die Vermutung nahe, dass sowohl das HRP-Modell, als auch Markowitz die Volatilität verringert haben. Der Preis für diese Reduzierte Volatilität ist demnach eine geringere Wertentwicklung. Auch die großen Verluste 2021 und 2025 fallen bei HRP und Markowitz geringer aus.

Zur Validierung der aus dem Performance-Plot abgeleiteten Volatilitätseigenschaften werden nun die Volatilitäten der Modelle gegeneinander geplottet. Abbildung 8 zeigt exemplarisch den Verlauf für eine halbjährliche Rebalancing-Frequenz.

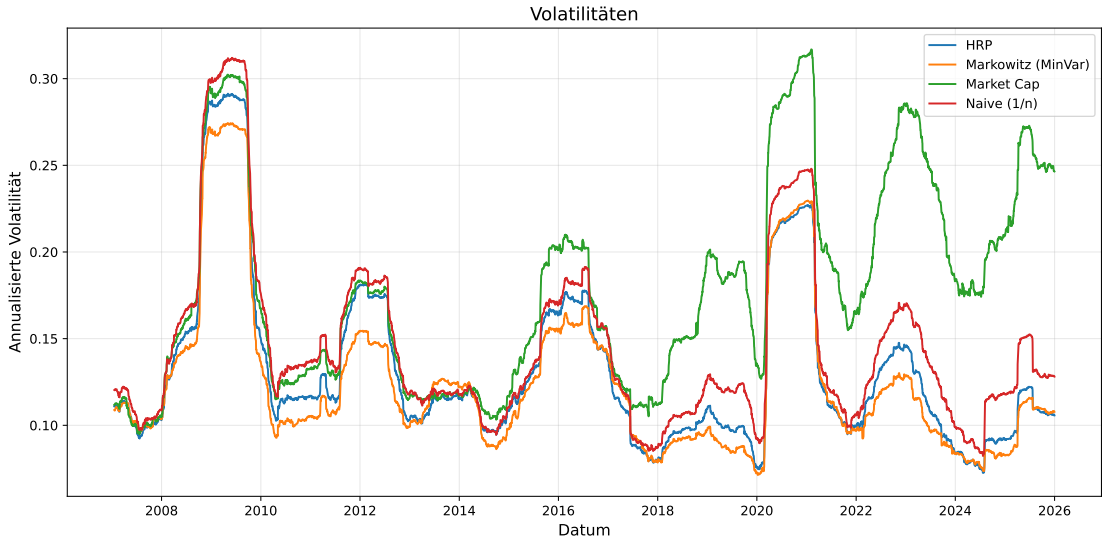


Abbildung 8: Volatilitäten der Allokationsansätze (halbjährlich)

Der Plot der Volatilitäten bestätigt die aus dem Performance-Plot abgeleiteten Eigenschaften. HRP und Markowitz verringern das Risiko gegenüber der naiven Diversifikation und dem marktgewichteten Portfolio über nahezu den gesamten Betrachtungszeitraum. Markowitz liefert fast durchgehend die geringste Volatilität, dicht gefolgt von HRP, welches punktuell ein nahezu identisches Risikoniveau erreicht. Lediglich im Jahr 2014 ist die Volatilität der Markowitz-Optimierung höher als die der Anderen. Besonders prägnant ist der Anstieg der Volatilität des marktgewichteten Portfolios im Jahr 2020.

Nach der Analyse von Wertentwicklung und Risiko wird im Folgenden die zeitliche Dynamik der Gewichtsverteilung untersucht. Dazu dienen Area-Plots, welche die Allokationsveränderungen über den gesamten Betrachtungszeitraum veranschaulichen. Auf die Darstellung der naiven Diversifikation wird an dieser Stelle verzichtet, da deren Portfolio-Gewichte konstruktionsbedingt zu jedem Rebalancing-Zeitpunkt konstant bei $1/N$ liegen.

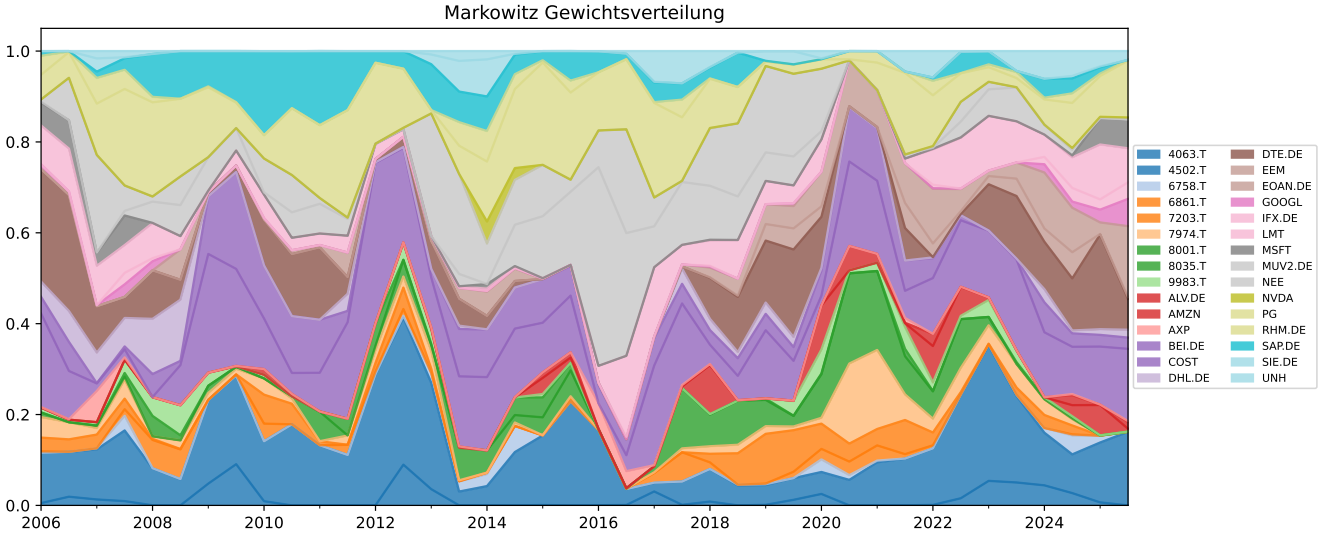


Abbildung 9: Area-Plot der Gewichte für die Markowitz-Optimierung (halbjährlich)

Die Gewichtsverteilung bei der Markowitz-Optimierung schwankt sehr stark. Außerdem erkennt man, dass wenige Assets hohe Gewichte erhalten. Der Area-Plot legt also nahe dass Markowitz bei jedem Rebalancing große Veränderungen an der Portfoliozusammensetzung vornimmt. Auch wenn in dieser Arbeit die Transaktionskosten nicht berücksichtigt werden, würden die starken Schwankungen bei den Gewichten in der Praxis erhöhte Kosten verursachen.

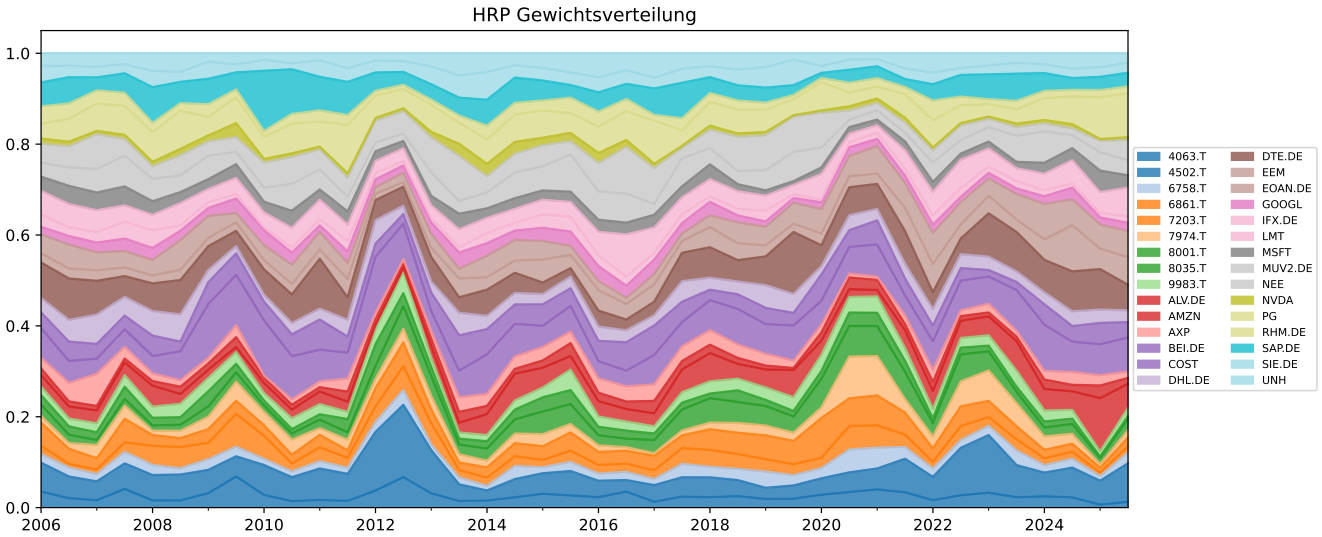


Abbildung 10: Area-Plot der Gewichte für das HRP-Modell (halbjährlich)

Die Gewichtsverteilung beim HRP-Modell ist deutlich gleichmäßiger. Zwar gibt es auch hier Phasen wo die Gewichte stark schwanken, allerdings treten diese starken Schwankungen in Zeiträumen auf wo der Markt aufgrund von Krisen instabil war. Auch fällt sofort auf dass mehr Assets überhaupt mit Gewichten größer null versehen werden. Anders als bei Markowitz scheinen die Gewichte hier eher stabil zu sein, HRP nimmt also weniger starke Änderungen pro Rebalancing vor als Markowitz.

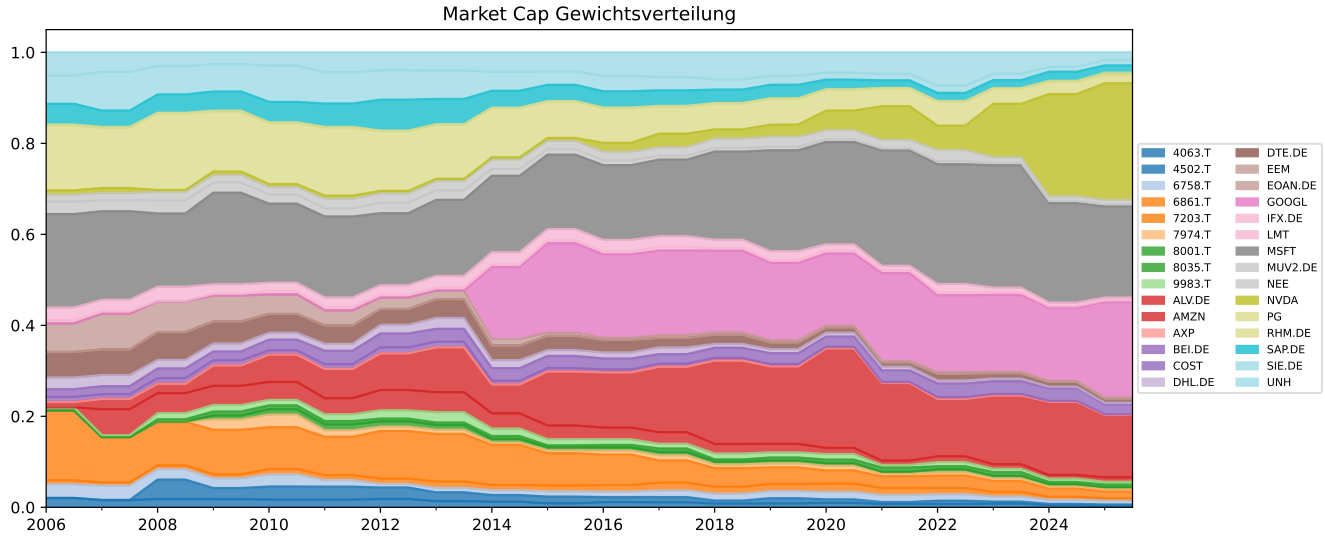


Abbildung 11: Area-Plot der Gewichte für das marktgewichtete Portfolio (halbjährlich)

Obwohl beim marktgewichteten Portfolio keine mathematische Optimierung stattfindet, illustriert dessen Area-Plot eindrucksvoll die zeitliche Entwicklung der Marktdominanz einzelner Titel. Insbesondere die zunehmende Flächenkonzentration ab dem Jahr 2020 verdeutlicht das entstehende Klumpenrisiko, welches die zuvor gezeigte hohe Volatilität dieses Ansatzes erklärt.

Abschließend werden die Daten zur Performance für alle drei Rebalancing-Frequenzen als Gesamtes betrachtet. Zunächst sollen HRP und Markowitz mit der naiven Diversifikation verglichen werden.

Tabelle 3: Vergleich der Performance über verschiedene Rebalancing-Frequenzen (naiv)

Metrik	**Quartalsweise**			**Halbjährlich**			**Jährlich**		
	HRP	MinVar	$1/n$	HRP	MinVar	$1/n$	HRP	MinVar	$1/n$
Ann. Rendite	9,61%	8,44%	10,99%	9,63%	8,74%	10,99%	9,32%	7,79%	10,99%
Ann. Volatilität	13,72%	12,98%	15,26%	13,96%	13,20%	15,26%	14,10%	13,30%	15,26%
Sharpe Ratio	**0,701**	0,650	0,720	**0,690**	0,662	0,720	**0,661**	0,586	0,720
Max. Drawdown	-47,5%	-43,7%	-51,6%	-47,7%	-43,3%	-51,6%	-49,0%	-42,8%	-51,6%
Avg. Turnover	0,256	0,427	0,000	0,321	0,627	0,000	0,394	0,876	0,000

Zunächst zeigt sich, dass die Vermutungen bezüglich Rendite, Volatilität, Gewichtsstabilität und maximalem Drawdown aus den Abbildungen 7, 9 und 10 durch die empirischen Ergebnisse in Tabelle 3 bestätigt werden.

Konkret verringern beide optimierten Modelle erwartungsgemäß die Volatilität und somit das Gesamtrisiko im Vergleich zur naiven Diversifikation ($1/n$), was jedoch mit einer reduzierten Rendite einhergeht. Dies spiegelt sich auch im maximalen Drawdown wider, der bei beiden optimierten Ansätzen deutlich geringer ausfällt als beim $1/n$-Portfolio. Dabei weist die klassische Markowitz-Optimierung (MinVar) über alle Rebalancing-Frequenzen hinweg stets die niedrigsten Werte für Volatilität und Drawdown auf.

Auch die Stabilität der Allokation – gemessen am durchschnittlichen Umschichtungsvolumen (Avg. Turnover) – fällt bei HRP erwartungsgemäß deutlich günstiger aus als bei MinVar. Bei halbjährlicher und jährlicher Rebalancing-Frequenz halbiert sich der Turnover durch den HRP-Ansatz nahezu. Zwar werden Transaktionskosten im Rahmen dieser Arbeit nicht explizit modelliert, jedoch würde deren Berücksichtigung die Nettoperformance des MinVar-Ansatzes aufgrund des hohen Umschichtungsbedarfs stärker belasten.

Der vielleicht interessanteste Wert ist das Sharpe-Ratio. Denn es quantifiziert die Effizienz eines Portfolios. Hier sieht man dass die naive Diversifikation über alle Frequenzen das höchste und somit beste Sharpe-Ratio aufweist. Dieses Phänomen konnte Victor DeMiguel bereits in seiner Arbeit von 2009 erklären (DeMiguel et al., 2009, S. 1947) Auffällig ist auch, dass HRP über alle Frequenzen das bessere Sharpe-Ratio als Markowitz aufweist. Beide Modelle scheinen allerdings von einer höheren Rebalancing-Frequenz zu profitieren, denn je höher die Frequenz ist, desto effizienter werden die HRP- bzw. Markowitz-Portfolios.

Im nächsten Schritt werden die Allokationsstrategien mit dem zweiten Benchmark, also dem marktgewichteten Portfolio verglichen.

Tabelle 4: Vergleich der Performance über verschiedene Rebalancing-Frequenzen

Metrik	**Quartalsweise**			**Halbjährlich**			**Jährlich**		
	HRP	MinVar	M. Cap	HRP	MinVar	M. Cap	HRP	MinVar	M. Cap
Ann. Rendite	9,61%	8,44%	16,00%	9,63%	8,74%	15,36%	9,32%	7,79%	16,00%
Ann. Volatilität	13,72%	12,98%	18,80%	13,96%	13,20%	18,77%	14,10%	13,30%	18,80%
Sharpe Ratio	0,701	0,650	**0,851**	0,690	0,662	**0,818**	0,661	0,586	**0,851**
Max. Drawdown	-47,5%	-43,7%	-42,9%	-47,7%	-43,3%	-44,1%	-49,0%	-42,8%	-42,9%
Avg. Turnover	0,256	0,427	0,042	0,321	0,627	0,084	0,394	0,876	0,169

Beim Vergleich mit dem marktgewichteten Portfolio (*Market Cap*) zeigt sich ein noch prägnanteres Bild. Das marktgewichtete Portfolio erzielt über alle Rebalancing-Frequenzen hinweg die mit Abstand höchste annualisierte Rendite und weist auch das höchste Sharpe-Ratio im gesamten Testfeld auf.

Dieser deutliche Renditevorsprung ist maßgeblich auf die starke Entwicklung von Schwergewichten (insbesondere aus dem Tech-Sektor) im vergangenen Jahrzehnt zurückzuführen. Wie aus den vorherigen Analysen hervorgeht, wird diese hohe Rendite jedoch durch ein spürbar höheres Risikoprofil erkauft: Mit einer annualisierten Volatilität von knapp 18,8% liegt das Risiko des marktgewichteten Portfolios deutlich über dem Niveau von HRP (ca. 13,7% – 14,1%) und MinVar (ca. 13,0% – 13,3%).

Besonders auffällig ist die weitgehende Invarianz der Performance-Kennzahlen gegenüber der gewählten Rebalancing-Frequenz beim marktgewichteten Portfolio. Der beobachtete Anstieg des durchschnittlichen Turnovers – von 0,042 bei quartalsweisem auf 0,169 bei jährlichem Rebalancing – lässt sich durch die Datenstruktur und den zeitlichen Drift erklären: Da die Marktkapitalisierungen in den Eingangsdaten auf jährlicher Basis vorliegen, führen unterjährige Rebalancing-Schritte lediglich zu feinen Justierungen gegen den kurzfristigen Kursdrift auf Basis konstanter Zielgewichte. Bei jährlicher Betrachtung hingegen fällt das Rebalancing mit der Aktualisierung der Marktkapitalisierungen zusammen. Der stärkere Gewichtsdrift über den gesamten Zwölfmonatszeitraum sowie die Anpassung an die neuen Kapitalisierungswerte führen schließlich zu einem kumuliert höheren Umschichtungsvolumen am Jahresende.

Zusammenfassend bestätigen beide Tabellen die theoretischen Erwartungen: Während die optimierten Ansätze (HRP und Markowitz) primär darauf ausgelegt sind, das Risiko effektiv zu minimieren und eine hohe Stabilität zu gewährleisten, profitierte das marktgewichtete Portfolio im Beobachtungszeitraum maximal vom anhaltenden Bullenmarkt der Large-Cap-Titel.

Erweiterter Modellvergleich (Maximum-Sharpe-Ratio):

Um die mathematischen Allokationsmodelle über die reinen risikobasierten Ansätze hinaus um eine aktive, renditeorientierte Komponente zu ergänzen, wird nachfolgend ein erweiterter Vergleich gezogen. In Tabelle 5 werden die Ergebnisse des HRP-Modells und der klassischen MinVar-Optimierung dem theoretisch effizienten Maximum-Sharpe-Ratio-Portfolio (MSR) gegenübergestellt.

Tabelle 5: Modellvergleich der mathematischen Optimierungsansätze (inkl. MSR)

Metrik	**Quartalsweise**			**Halbjährlich**			**Jährlich**		
	HRP	MinVar	MSR	HRP	MinVar	MSR	HRP	MinVar	MSR
Ann. Rendite	9,61%	8,44%	13,24%	9,63%	8,74%	18,87%	9,32%	7,79%	13,28%
Ann. Volatilität	13,72%	12,98%	20,45%	13,96%	13,20%	20,77%	14,10%	13,30%	20,46%
Sharpe Ratio	**0,701**	0,650	0,647	**0,690**	0,662	0,909	**0,661**	0,586	0,649
Max. Drawdown	-47,5%	-43,7%	-36,7%	-47,7%	-43,3%	-35,6%	-49,0%	-42,8%	-60,5%
Avg. Turnover	0,256	0,427	1,006	0,321	0,627	1,254	0,394	0,876	1,622

Während MinVar und HRP rein risikofokussiert agieren, versucht das MSR-Portfolio per Definition, die Sharpe-Ratio im jeweiligen Schätzfenster zu maximieren. Die Konsequenz dieser renditeorientierten Optimierung ist ein sprunghafter Anstieg des Risikos: Die annualisierte Volatilität verweilt über alle Betrachtungsintervalle hinweg auf einem hohen Niveau von über 20,4 %.

Eine bemerkenswerte Anomalie zeigt sich bei der halbjährlichen Rebalancing-Frequenz, bei der der MSR-Ansatz eine Ausreißer-Rendite von 18,87 % (Sharpe-Ratio 0,909) erzielt. Aus finanzmathematischer Sicht ist dieses Ergebnis jedoch nicht als struktureller Vorteil des Modells zu werten. Dass diese deutliche Überrendite ausschließlich bei der halbjährlichen Frequenz auftritt und bei quartalsweisem sowie jährlichem Rebalancing wieder bricht, belegt die extreme Sensitivität des Modells gegenüber den gewählten Stichtagsdaten. Es handelt sich somit um einen reinen In-Sample-Effekt der historischen Datenkonstellation und nicht um eine robust reproduzierbare Strategie.

Die Instabilität dieser Schätzfehler-Abhängigkeit wird beim Wechsel zur jährlichen Anpassung besonders deutlich: Hier fällt die Sharpe-Ratio des MSR-Portfolios wieder auf $0,649$ zurück, während der maximale Drawdown auf $-60,5\,\%$ einbricht. Aufgrund des langen Rebalancing-Intervalls kann die Allokation unterjährigen Marktschocks nicht entgegenwirken, wodurch das Portfolio Verlustphasen ungesteuert ausgesetzt bleibt.

Zusätzlich wird die praktische Relevanz des MSR-Ansatzes durch das hohe Umschichtungsvolumen relativiert. Während HRP über alle Intervalle hinweg den geringsten Turnover aufweist, erreicht das MSR-Modell bei jährlicher Frequenz einen Extremwert von 1,622 (und 1,257 bei halbjährlicher Frequenz). Ein derart hoher periodischer Umschlag würde unter Berücksichtigung realer Transaktionskosten einen substanziellen Teil der theoretischen Rendite vernichten.

Zusammenfassung:

Die Ergebnisse dieser Arbeit bestätigen die theoretisch zugeschriebenen Vorteile des Hierarchical Risk Parity (HRP)-Ansatzes. Hinsichtlich der zentralen Forschungsfrage zeigt sich, dass HRP im Vergleich zur klassischen Markowitz-Optimierung sowohl eine höhere Gewichtszeitstabilität als auch ein überlegenes Risiko-Rendite-Verhältnis aufweist.

Die Analyse der Konditionszahl belegt die numerische Instabilität der klassischen Markowitz-Optimierung unter realen Marktbedingungen. Der HRP-Algorithmus umgeht diese Inversionsproblematik konstruktionsbedingt, was sich empirisch in einer signifikant höheren Gewichtsstabilität (geringerem Turnover) niederschlägt. Zudem weisen die HRP-Portfolios über alle untersuchten Rebalancing-Frequenzen hinweg eine höhere Effizienz (gemessen an der Sharpe-Ratio) auf.

Demgegenüber steht die stärkere reine Risikominimierung des Markowitz-Modells: Dieses reduziert die Gesamtvolatilität konsequenter als HRP, nimmt dafür jedoch so deutliche Renditeeinbußen in Kauf, dass das Gesamtergebnis weniger effizient ausfällt. Für Investoren, deren vorrangiges Ziel die maximale Reduktion der absoluten Volatilität ist, bleibt die Markowitz-Optimierung somit die bevorzugte Wahl, während HRP die praxisnähere und robustere Gesamtlösung bietet.

6 Ausblick

Diese Untersuchung hat die Vorteile von HRP-Algorithmus gegenüber der Markowitz-Optimierung aufgezeigt. Jedoch ergeben sich aus dieser Arbeit spannende Ansätze für zukünftige Untersuchungen.

1. Integration eines realen Kostenmodells:

HRP lieferte in dieser Untersuchung ein deutlich geringeres Turnover als die Markowitz-Optimierung. Da in dieser Arbeit allerdings die Transaktionskosten vernachlässigt wurden, sind die berechneten Werte Bruttowerte. Eine Folgeuntersuchung könnte unter Berücksichtigung dieser Kosten zu dem Ergebnis kommen, dass der Effizienzvorteil von HRP noch größer ist, denn durch das höhere Turnover, würde bei der Markowitz-Optimierung die Nettorendite stärker belastet werden.

2. Analyse des 1/N Portfolios:

Die naive Diversifikation hat interessanterweise über alle betrachteten Frequenzen das effizienteste Portfolio geliefert. In einer Folgestudie könnte betrachtet werden ob es eine Portfoliogröße gibt, ab der die Optimierungsverfahren ihren theoretischen Vorteil gegenüber der naiven Diversifikation besser ausspielen können.

3. Variieren weiterer Modell-Parameter:

In dieser Arbeit wurden drei Frequenzen betrachtet. Allerdings gibt es noch weitere Parameter die man variieren kann. Bspw. wurde hier als Datengrundlage für die Schätzung der Marktparameter eine Zeitraum von einem Jahr gewählt (250 Handelstage). Diesen Zeitraum könnte man in einer späteren Untersuchung variieren, um zu prüfen ob die Modelle von einer größeren Datengrundlage profitieren.

Abschließend lässt sich festhalten, dass HRP eine wichtige Brücke zwischen der modernen Portfoliotheorie und den Anforderungen an numerische Stabilität schlägt. Während die klassische Optimierung ein wertvolles theoretisches Fundament bleibt, bietet der hierarchische Ansatz eine Antwort auf die Herausforderungen verrauschter Finanzmarktdaten.

4. Erweiterung des Datenuniversums zur Vermeidung des Survivorship Bias: In dieser Arbeit wurde ein überlebendes Asset-Universum aus 30 durchgehend gelisteten Titeln analysiert. Eine wertvolle Ergänzung für zukünftige Untersuchungen wäre die Verwendung eines dynamischen historischen Anlageuniversums, das auch gescheiterte, delistete oder fusionierte Unternehmen einschließt. Auf diese Weise ließe sich empirisch prüfen, wie robust das HRP-Verfahren im direkten Vergleich zu Markowitz reagiert, wenn reale Ausfallrisiken und drastische Korrelationsbrüche im Universum auftreten.

Literaturverzeichnis

DeMiguel, V., Gerlappi, L., & Uppal, R. (2009). Optimal Versus Naive Diversification: How Inefficent is the 1/N Portfolio Strategy? *The Review of Financial Studies*.

Kremer, J. (2023). *Marktrisiken*. Springer.

López de Prado, M. (2016). Building Diversified Portfolios that outperform out-of-sample. *Journal of Portfolio Management*.

López de Prado, M. (2018). *Advances in Financial Machine Learning*. John Wiley & Sons.

Nickel, S., Rebennack, S., Stein, O., & Waldmann, K.-H. (2022). *Operations Research*. Springer.

7 Anhang

7.1 Performance-Plots

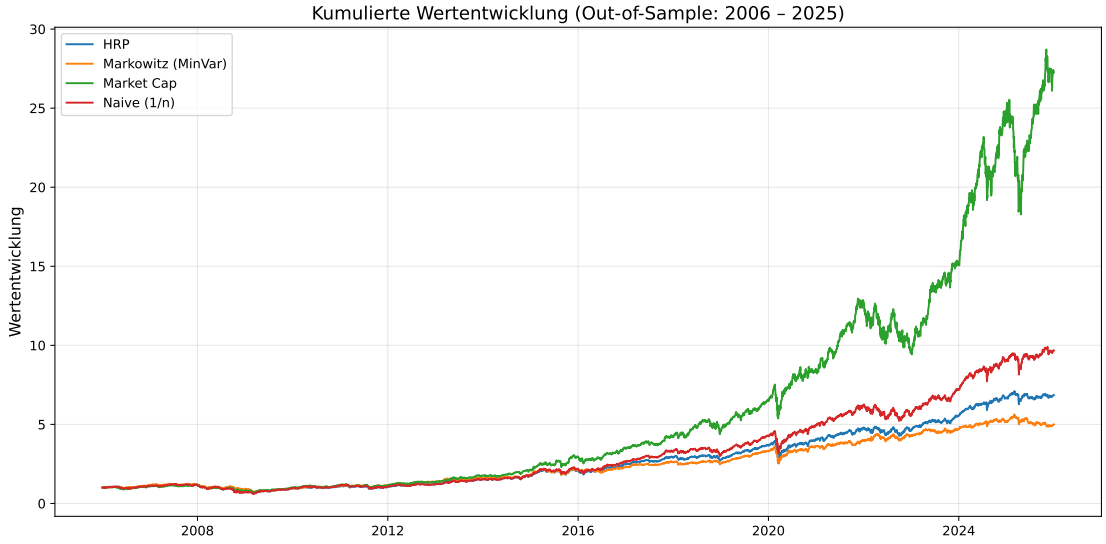


Abbildung 12: Performance der Modelle bei jährlicher Rebalancing-Frequenz

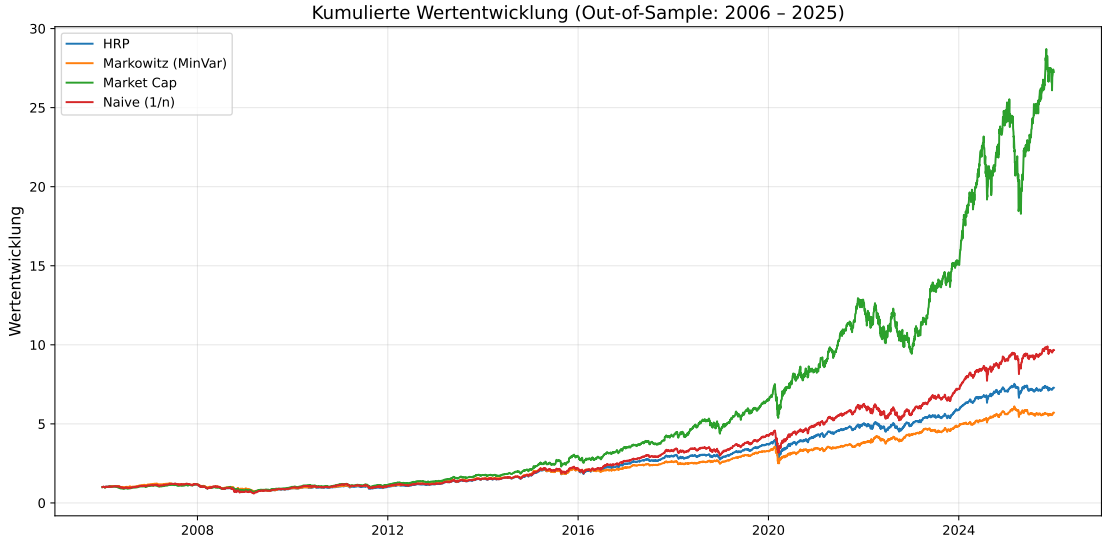


Abbildung 13: Performance der Modelle bei quartalsweiser Rebalancing-Frequenz

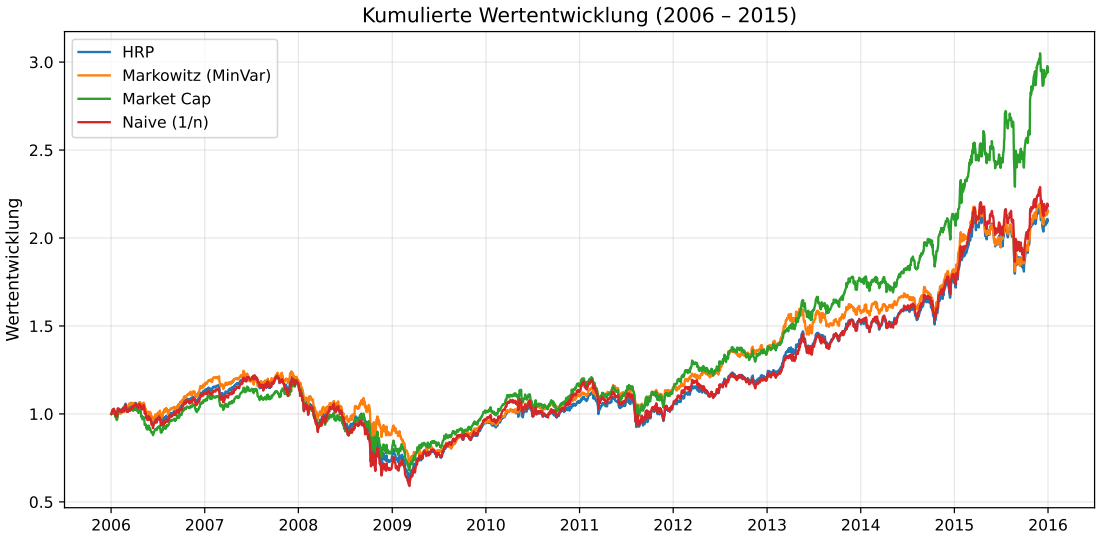


Abbildung 14: Performance der Modelle bei jährlicher Rebalancing-Frequenz (2006-2015)

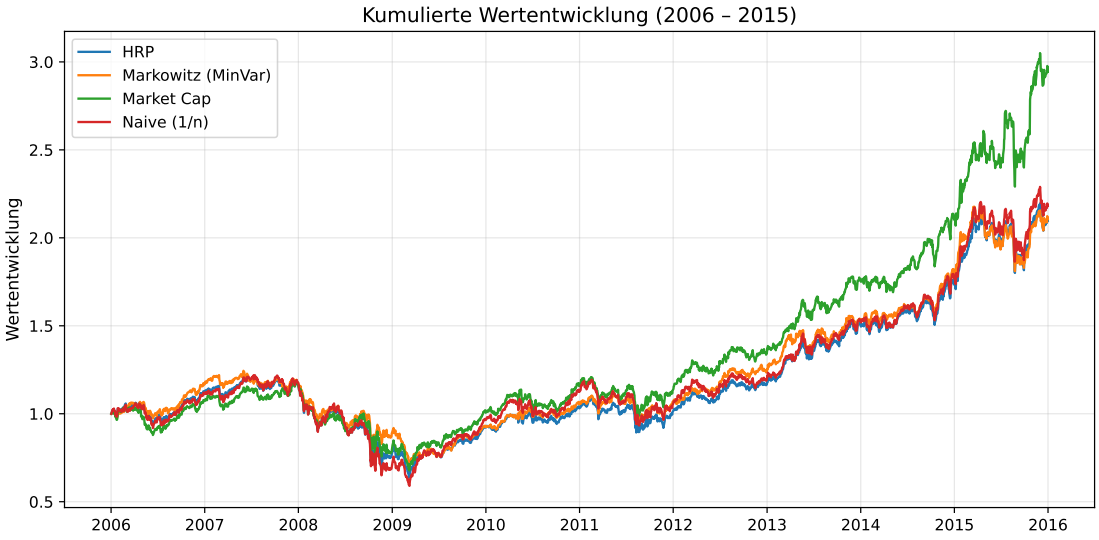


Abbildung 15: Performance der Modelle bei quartalsweiser Rebalancing-Frequenz (2006-2015)

7.2 Konditions-Plots

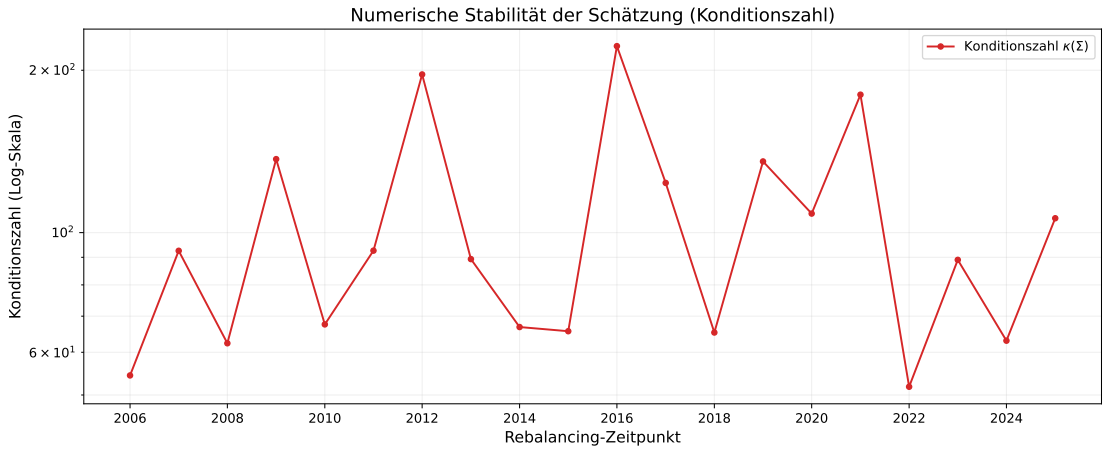


Abbildung 16: Konditionszahl (jährlich) über die Zeit

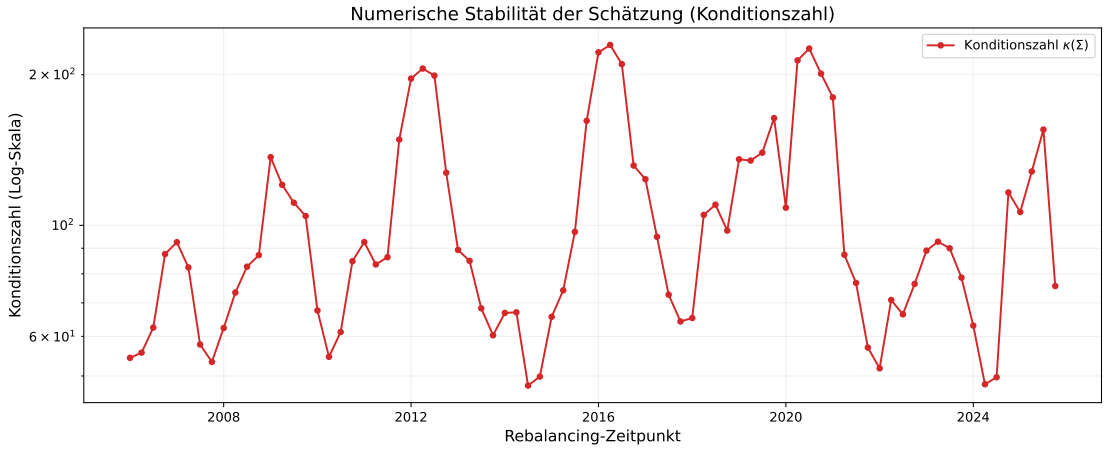


Abbildung 17: Konditionszahl (quartalsweise) über die Zeit

7.3 Area-Plots

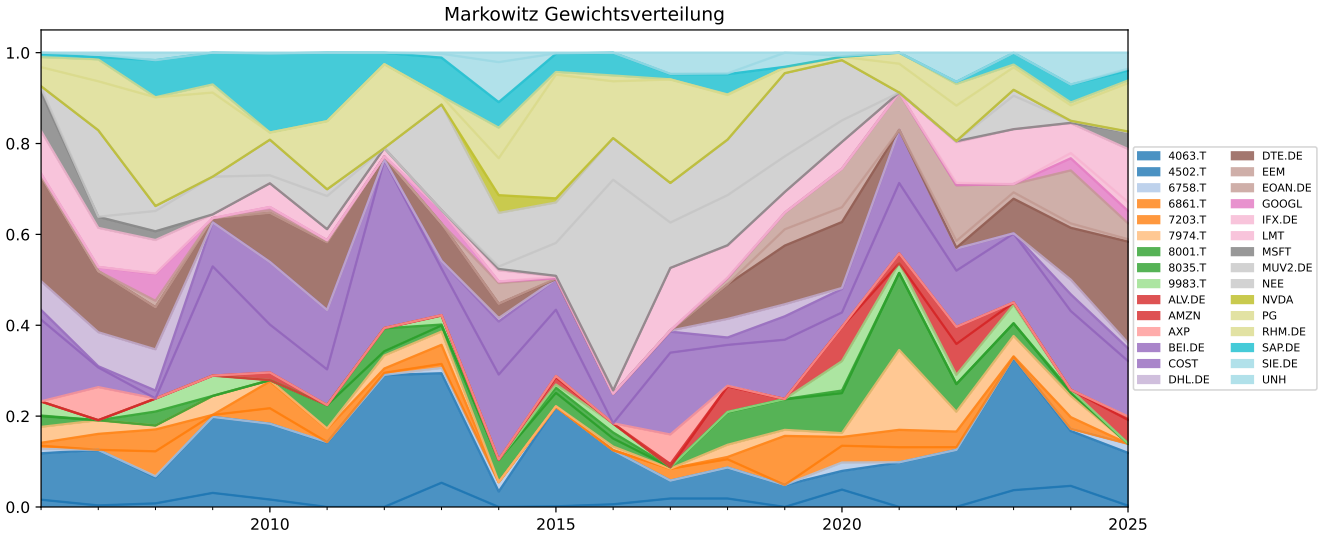


Abbildung 18: Area-Plot der Gewichte für die Markowitz-Optimierung (jährlich)

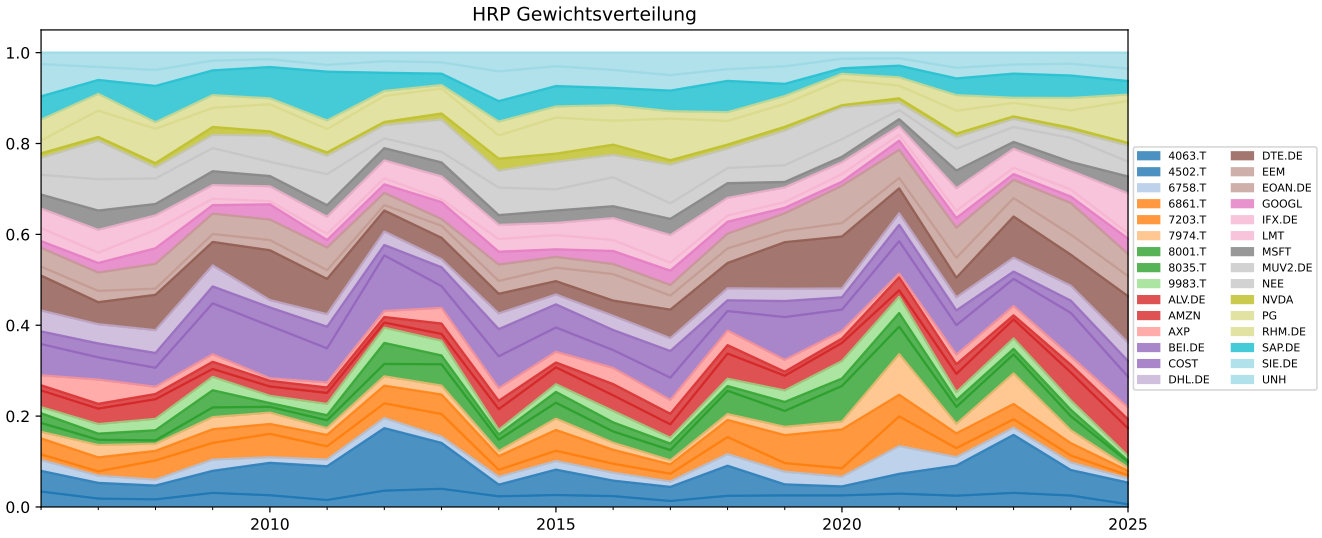


Abbildung 19: Area-Plot der Gewichte für das HRP-Modell (jährlich)

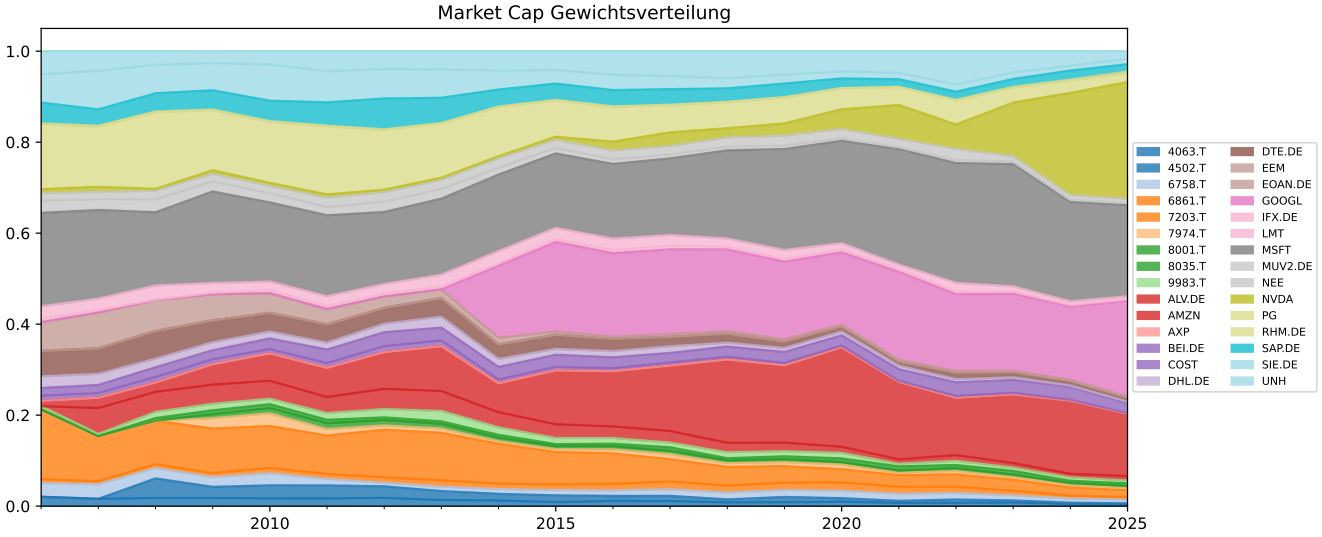


Abbildung 20: Area-Plot der Gewichte für das Market-Cap-Portfolio (jährlich)

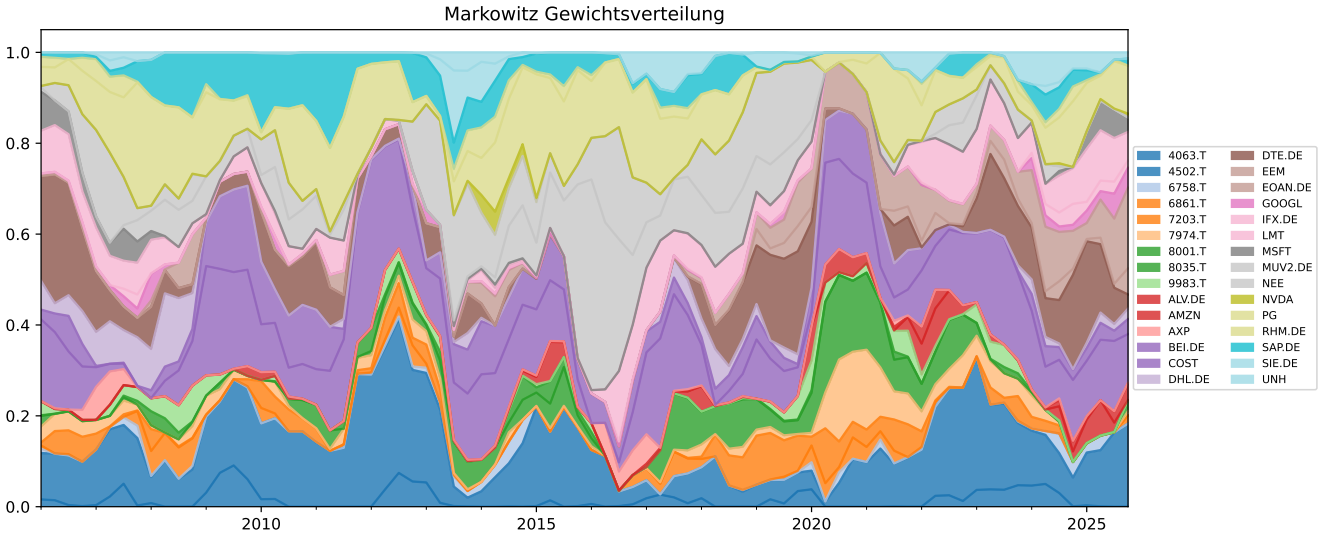


Abbildung 21: Area-Plot der Gewichte für die Markowitz-Optimierung (quartalsweise)

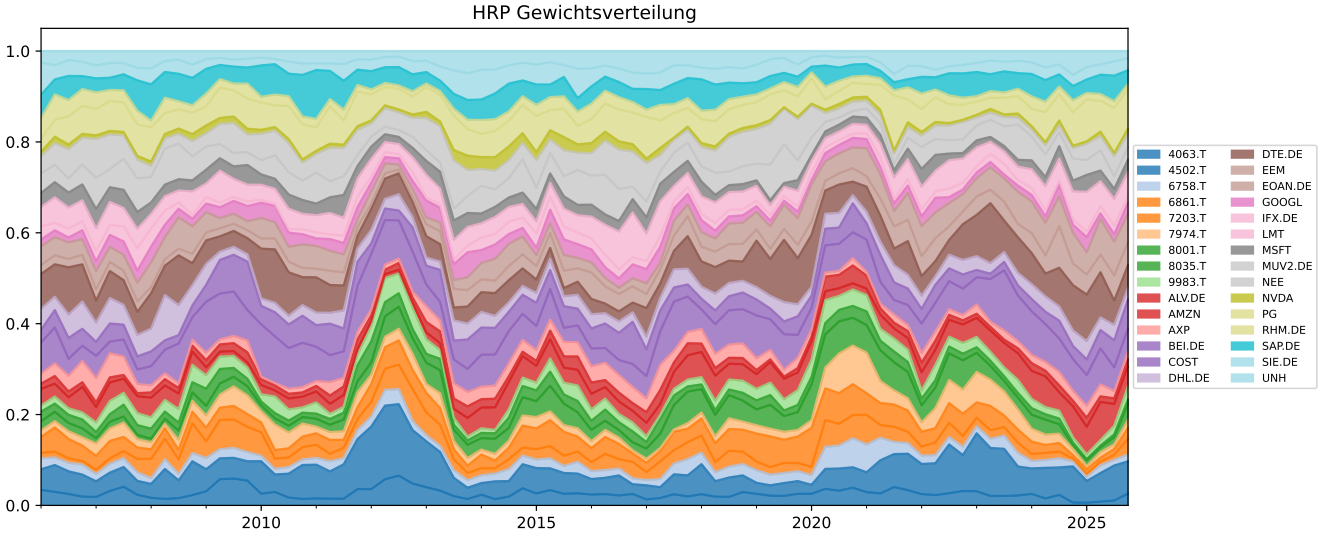


Abbildung 22: Area-Plot der Gewichte für das HRP-Modell (quartalsweise)

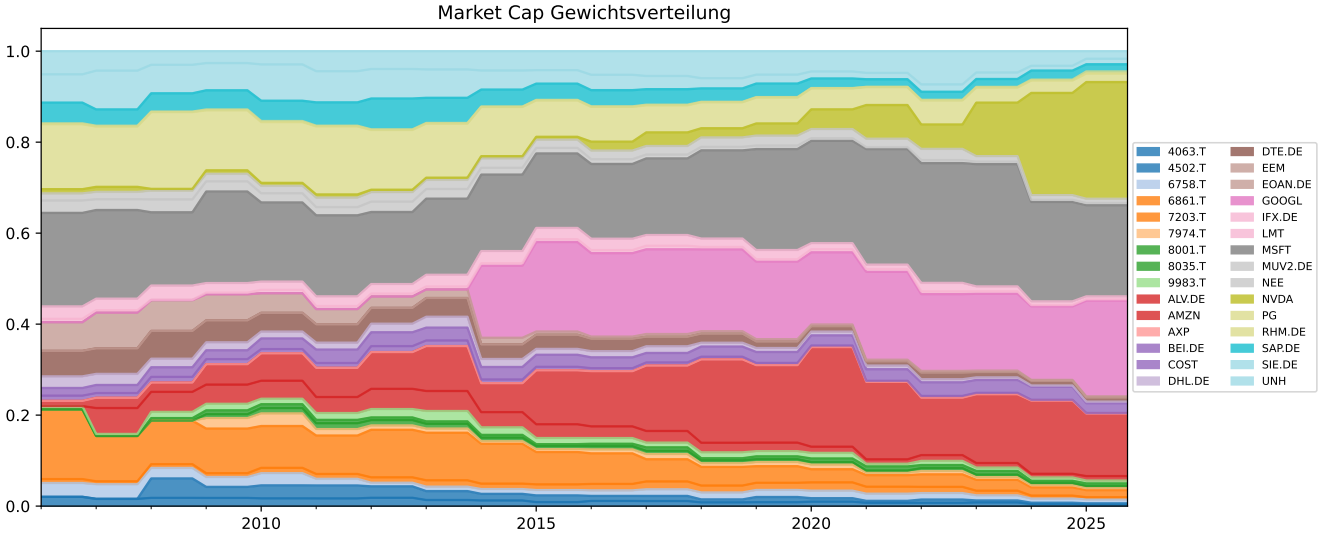


Abbildung 23: Area-Plot der Gewichte für das Market-Cap-Portfolio (quartalsweise)

7.4 Tabellen

Tabelle 6: Durchschnittliche Konditionszahl der Kovarianzmatrizen (unregularisiert) nach Rebalancing-Frequenz

Rebalancing-Frequenz	**Ø Konditionszahl** $\kappa(\Sigma)$
Quartalsweise	103,42
Halbjährlich	102,50
Jährlich	103,47

7.5 Python-Code

Der Code zu dieser Arbeit befindet sich in folgendem GitHub-Repository:

https://github.com/PrimeC0de99/BA_Portfolio_Opt

Eigenständigkeitserklärung

Ich versichere hiermit, dass ich die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet und diese Arbeit noch nicht zum Erwerb von anderen Leistungsnachweisen verwendet habe. Sämtliche wörtlichen oder sinngemäßen Übernahmen und Zitate sind kenntlich gemacht und nachgewiesen. Ich versichere, dass ich keine Hilfsmittel verwendet habe, deren Nutzung die Prüferin oder der Prüfer explizit ausgeschlossen hat. Alle verwendeten Hilfsmittel habe ich vollständig und in geeigneter Form kenntlich gemacht.

Mit Abgabe der vorliegenden Leistung übernehme ich die Verantwortung für das eingereichte Gesamtprodukt.

Bei Verwendung von Künstlicher Intelligenz (KI): Ich verantworte jegliche KI-generierten Inhalte, die ich in meine Arbeit übernommen habe. Die Richtigkeit übernommener (KI-generierter) Aussagen und Inhalte habe ich nach bestem Wissen und Gewissen geprüft und die verwendeten Stellen in der Arbeit kenntlich gemacht.

Bei Verstößen gegen die vorstehende Erklärung wird die Arbeit mit „nicht bestanden“ bzw. „nicht ausreichend“ bewertet und als Täuschungsversuch entsprechend der Prüfungsordnung geahndet.

Zur Plagiatsüberprüfung erfolgt die elektronische Übermittlung der Leistungen an den Dienstleister der Software die die Hochschule Koblenz für die Überprüfung verwendet. Dort werden diese elektronisch auf Übereinstimmung mit externen Quellen abgeglichen. Weiter werden die Leistungen dauerhaft elektronisch in einer ausschließlich für die Hochschule Koblenz geführten und nur ihr zugänglichen Datenbank gespeichert, um zukünftige Leistungen auf Übereinstimmung mit diesen bereits verfassten Leistungen überprüfen zu können.

Die dauerhafte Speicherung von Leistungen sowie die Weitergabe persönlicher Daten der Urheberin/ des Urhebers im Zusammenhang mit dieser Plagiatsprüfung ist nur mit dem Einverständnis der Urheberin/ des Urhebers der Leistung möglich.

Ich erkläre hiermit freiwillig und jederzeit widerrufbar mein Einverständnis damit, dass

- die vorgelegte Leistung dauerhaft in der zum Zweck der Überprüfung von Leistungen für die Hochschule Koblenz geführten Datenbank elektronisch gespeichert wird;
- meine persönlichen Daten (Name, Vorname, Hochschul- E-Mail - Adresse) zusammen mit der Leistung in der für die Hochschule Koblenz geführten Datenbank elektronisch gespeichert und verwendet werden. Diese Daten sind nur meinen Prüfern sowie der/dem in deren Auftrag tätigen Systemadministratorin/Systemadministrator der Hochschule Koblenz zugänglich.

Ich bin damit einverstanden, dass diese Arbeit in elektronischer Form hochschulintern über den lokalen Bibliotheksrechner eingesehen werden kann. Das Recht der Veröffentlichung oder Verwertung durch den/die Verfasser/in auf andere Weise, z.B. über einen Verlag, bleibt davon unberührt. Die Hochschule ist nicht verpflichtet, die Arbeit zu veröffentlichen. Das Einverständnis kann jederzeit schriftlich durch den Verfasser widerrufen werden. Das Prüfungsamt wird die Arbeit dann unverzüglich entfernen.

☐ ja ☐ nein

_____ _____

Ort, Datum Unterschrift